Анализ бизнес-показателей Яндекс.Афиши

Описание проекта

Вас пригласили на стажировку в отдел аналитики Яндекс.Афиши. Первое задание: помочь маркетологам оптимизировать маркетинговые затраты.

У нас в распоряжении есть данные от Яндекс.Афиши с июня 2017 по конец мая 2018 года:

- лог сервера с данными о посещениях сайта Яндекс.Афиши,
- выгрузка всех заказов за этот период,
- статистика рекламных расходов.

Мы изучим:

- как люди пользуются продуктом,
- когда они начинают покупать,
- сколько денег приносит каждый клиент
- когда клиент окупается.

Описание данных

Данные представлены в файлах

- _/datasets/visits*log.csv*.
- _/datasets/orders*log.csv*.
- */datasets/costs.csv*.

Таблица `visits` (лог сервера с информацией о посещениях сайта):

- *Uid* — уникальный идентификатор пользователя
- *Device* — категория устройства пользователя
- Start Ts — дата и время начала сессии
- End Ts — дата и время окончания сессии
- Source Id — идентификатор рекламного источника, из которого пришел пользователь

Таблица `orders` (информация о заказах):

- *Uid* — уникальный id пользователя, который сделал заказ
- *Buy Ts* — дата и время заказа
- *Revenue* — выручка Яндекс.Афиши с этого заказа

Таблица `costs` (информация о затратах на маркетинг):

- *source_id* — идентификатор рекламного источника
- *dt* — дата
- *costs* — затраты на этот рекламный источник в этот день

Оглавление

1. Загрузка и подготовка данных к анализу

Загрузите данные о визитах, заказах и расходах в переменные. Оптимизируйте данные для анализа. Убедитесь, что тип данных в каждой колонке — правильный.

In [1]:
```
# For better figure's quality
%config InlineBackend.figure_format = 'retina'
import pandas as pd
import numpy as np
```

```
import matplotlib.pyplot as plt
import seaborn as sns
```

In [2]:
```
# For better printing
pd.set_option('display.max_columns', 10)
```

In [3]:
```
# workaround to use praktikum file system as well as local windows system
try:
    costs = pd.read_csv('/datasets/costs.csv')
    orders_log = pd.read_csv('/datasets/orders_log.csv')
    visits_log = pd.read_csv('/datasets/visits_log.csv')
except:
    costs = pd.read_csv('datasets/costs.csv')
    orders_log = pd.read_csv('datasets/orders_log.csv')
    visits_log = pd.read_csv('datasets/visits_log.csv')
```

In [4]:
```
costs.head()
```

Out[4]:

	source_id	dt	costs
0	1	2017-06-01	75.20
1	1	2017-06-02	62.25
2	1	2017-06-03	36.53
3	1	2017-06-04	55.00
4	1	2017-06-05	57.08

In [5]:
```
costs.info()
```

```
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 2542 entries, 0 to 2541
Data columns (total 3 columns):
 #   Column     Non-Null Count  Dtype
---  ------     --------------  -----
 0   source_id  2542 non-null   int64
 1   dt         2542 non-null   object
 2   costs      2542 non-null   float64
dtypes: float64(1), int64(1), object(1)
memory usage: 59.7+ KB
```

In [6]:
```
costs.isna().mean()
```

Out[6]:
```
source_id    0.0
dt           0.0
costs        0.0
dtype: float64
```

In [7]:
```
costs.duplicated().sum()
```

Out[7]:
```
0
```

В таблице `costs` нет пропусков или дубликатов. остается только преобразовать параметр `dt` в формат даты-времени.

In [8]:
```
costs['dt'] = pd.to_datetime(costs['dt'])
```

In [9]:
```
costs.info()
```

```
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 2542 entries, 0 to 2541
Data columns (total 3 columns):
 #   Column     Non-Null Count  Dtype
---  ------     --------------  -----
 0   source_id  2542 non-null   int64
 1   dt         2542 non-null   datetime64[ns]
 2   costs      2542 non-null   float64
dtypes: datetime64[ns](1), float64(1), int64(1)
memory usage: 59.7 KB
```

In [10]:
```
costs.head()
```

Out[10]:

	source_id	dt	costs
0	1	2017-06-01	75.20
1	1	2017-06-02	62.25
2	1	2017-06-03	36.53
3	1	2017-06-04	55.00
4	1	2017-06-05	57.08

Таблица `costs` готова к анализу.

In [11]:
```
orders_log.head()
```

Out[11]:

	Buy Ts	Revenue	Uid
0	2017-06-01 00:10:00	17.00	10329302124590727494
1	2017-06-01 00:25:00	0.55	11627257723692907447
2	2017-06-01 00:27:00	0.37	17903680561304213844
3	2017-06-01 00:29:00	0.55	16109239769442553005
4	2017-06-01 07:58:00	0.37	14200605875248379450

In [12]:
```
orders_log.info()
```

```
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 50415 entries, 0 to 50414
Data columns (total 3 columns):
 #   Column   Non-Null Count  Dtype
---  ------   --------------  -----
 0   Buy Ts   50415 non-null  object
 1   Revenue  50415 non-null  float64
 2   Uid      50415 non-null  uint64
dtypes: float64(1), object(1), uint64(1)
memory usage: 1.2+ MB
```

In [13]:
```
orders_log.isna().mean()
```

Out[13]:
```
Buy Ts     0.0
Revenue    0.0
Uid        0.0
dtype: float64
```

In [14]:
```
orders_log.duplicated().sum()
```

Out[14]:
```
0
```

В таблице `orders_log` нет пропусков или дубликатов. остается только преобразовать параметр `Buy Ts` в формат даты-времени и переименовать колонки по стандарту.

In [15]:
```
orders_log['Buy Ts'] = pd.to_datetime(orders_log['Buy Ts'])
```

In [16]:
```
orders_log.columns = ['buy_ts', 'revenue', 'uid']
```

In [17]:
```
orders_log.info()
```

```
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 50415 entries, 0 to 50414
Data columns (total 3 columns):
 #   Column   Non-Null Count  Dtype
---  ------   --------------  -----
 0   buy_ts   50415 non-null  datetime64[ns]
 1   revenue  50415 non-null  float64
 2   uid      50415 non-null  uint64
dtypes: datetime64[ns](1), float64(1), uint64(1)
memory usage: 1.2 MB
```

In [18]:
```
orders_log.head()
```

Out[18]:

	buy_ts	revenue	uid
0	2017-06-01 00:10:00	17.00	10329302124590727494
1	2017-06-01 00:25:00	0.55	11627257723692907447
2	2017-06-01 00:27:00	0.37	17903680561304213844
3	2017-06-01 00:29:00	0.55	16109239769442553005
4	2017-06-01 07:58:00	0.37	14200605875248379450

Таблица `orders_log` готова к анализу.

In [19]:
```
visits_log.head()
```

Out[19]:

	Device	End Ts	Source Id	Start Ts	Uid
0	touch	2017-12-20 17:38:00	4	2017-12-20 17:20:00	16879256277535980062
1	desktop	2018-02-19 17:21:00	2	2018-02-19 16:53:00	104060357244891740

	Device	End Ts	Source Id	Start Ts	Uid
2	touch	2017-07-01 01:54:00	5	2017-07-01 01:54:00	7459035603376831527
3	desktop	2018-05-20 11:23:00	9	2018-05-20 10:59:00	16174680259334210214
4	desktop	2017-12-27 14:06:00	3	2017-12-27 14:06:00	9969694820036681168

In [20]:
```
visits_log.info()
```

```
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 359400 entries, 0 to 359399
Data columns (total 5 columns):
 #   Column     Non-Null Count   Dtype 
---  ------     --------------   ----- 
 0   Device     359400 non-null  object
 1   End Ts     359400 non-null  object
 2   Source Id  359400 non-null  int64 
 3   Start Ts   359400 non-null  object
 4   Uid        359400 non-null  uint64
dtypes: int64(1), object(3), uint64(1)
memory usage: 13.7+ MB
```

In [21]:
```
visits_log.isna().mean()
```

Out[21]:
```
Device       0.0
End Ts       0.0
Source Id    0.0
Start Ts     0.0
Uid          0.0
dtype: float64
```

In [22]:
```
visits_log.duplicated().sum()
```

Out[22]:
```
0
```

В таблице `visits_log` нет пропусков или дубликатов. остается только преобразовать параметры даты-времени в нужный формат и переименовать колонки по стандарту.

In [23]:
```
visits_log['End Ts'] = pd.to_datetime(visits_log['End Ts'])
```

In [24]:
```
visits_log['Start Ts'] = pd.to_datetime(visits_log['Start Ts'])
```

In [25]:
```
visits_log.columns = ['device', 'end_ts', 'source_id', 'start_ts', 'uid']
```

In [26]:
```
visits_log.info()
```

```
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 359400 entries, 0 to 359399
Data columns (total 5 columns):
 #   Column     Non-Null Count   Dtype         
---  ------     --------------   -----         
 0   device     359400 non-null  object        
 1   end_ts     359400 non-null  datetime64[ns]
 2   source_id  359400 non-null  int64         
 3   start_ts   359400 non-null  datetime64[ns]
 4   uid        359400 non-null  uint64        
dtypes: datetime64[ns](2), int64(1), object(1), uint64(1)
memory usage: 13.7+ MB
```

In [27]:
```
visits_log.head()
```

Out[27]:

	device	end_ts	source_id	start_ts	uid
0	touch	2017-12-20 17:38:00	4	2017-12-20 17:20:00	16879256277535980062
1	desktop	2018-02-19 17:21:00	2	2018-02-19 16:53:00	104060357244891740
2	touch	2017-07-01 01:54:00	5	2017-07-01 01:54:00	7459035603376831527
3	desktop	2018-05-20 11:23:00	9	2018-05-20 10:59:00	16174680259334210214
4	desktop	2017-12-27 14:06:00	3	2017-12-27 14:06:00	9969694820036681168

Все таблицы готовы к анализу.

Вывод раздела 1

Мы прочитали исходные данные, проверили пропуски и дубликаты, преобразовали параметры даты-времени в соответствующие форматы и переименовали колонки по стандарту.

2. Подготовка отчетов и метрик

Подготовим отчет по продукту

- Сколько людей пользуются в день, неделю, месяц?
- Сколько сессий в день?
- Сколько длится одна сессия?
- Как часто люди возвращаются?

Для расчета сессий пользователей воспользуемся таблицей `visits` с информацией о визитах.

In [28]:
```
visits_log.head()
```

Out[28]:

	device	end_ts	source_id	start_ts	uid
0	touch	2017-12-20 17:38:00	4	2017-12-20 17:20:00	16879256277535980062
1	desktop	2018-02-19 17:21:00	2	2018-02-19 16:53:00	104060357244891740
2	touch	2017-07-01 01:54:00	5	2017-07-01 01:54:00	7459035603376831527
3	desktop	2018-05-20 11:23:00	9	2018-05-20 10:59:00	16174680259334210214
4	desktop	2017-12-27 14:06:00	3	2017-12-27 14:06:00	9969694820036681168

In [29]:
```
visits_log['session_day'] = visits_log['start_ts'].astype('datetime64[D]')
```

In [30]:
```
visits_log['session_month'] = visits_log['start_ts'].astype('datetime64[M]')
```

In [31]:
```
visits_log['session_week'] = visits_log['start_ts'].astype('datetime64[D]') \
                    - pd.to_timedelta(visits_log['start_ts'].dt.dayofweek, 'd')
```

In [32]:
```
visits_log
```

Out[32]:

	device	end_ts	source_id	start_ts	uid	session_day	session_month	session_week
0	touch	2017-12-20 17:38:00	4	2017-12-20 17:20:00	16879256277535980062	2017-12-20	2017-12-01	2017-12-18
1	desktop	2018-02-19 17:21:00	2	2018-02-19 16:53:00	104060357244891740	2018-02-19	2018-02-01	2018-02-19
2	touch	2017-07-01 01:54:00	5	2017-07-01 01:54:00	7459035603376831527	2017-07-01	2017-07-01	2017-06-26
3	desktop	2018-05-20 11:23:00	9	2018-05-20 10:59:00	16174680259334210214	2018-05-20	2018-05-01	2018-05-14
4	desktop	2017-12-27 14:06:00	3	2017-12-27 14:06:00	9969694820036681168	2017-12-27	2017-12-01	2017-12-25
...	...	...	...	...	...	...	...	...
359395	desktop	2017-07-29 19:07:19	2	2017-07-29 19:07:00	18363291481961487539	2017-07-29	2017-07-01	2017-07-24
359396	touch	2018-01-25 17:38:19	1	2018-01-25 17:38:00	18370831553019119586	2018-01-25	2018-01-01	2018-01-22
359397	desktop	2018-03-03 10:12:19	4	2018-03-03 10:12:00	18387297585500748294	2018-03-03	2018-03-01	2018-02-26
359398	desktop	2017-11-02 10:12:19	5	2017-11-02 10:12:00	18388616944624776485	2017-11-02	2017-11-01	2017-10-30
359399	touch	2017-09-10 13:13:19	2	2017-09-10 13:13:00	18396128934054549559	2017-09-10	2017-09-01	2017-09-04

359400 rows × 8 columns

Посчитаем длительность сессий с точностью до минут.

In [33]:
```
visits_log['session_duration'] = np.abs(visits_log['end_ts'] - visits_log['start_ts'])
```

In [34]:
```
visits_log['session_duration'] = visits_log['session_duration'] / np.timedelta64(1, 'm')
```

In [35]:
```
visits_log
```

Out[35]:

	device	end_ts	source_id	start_ts	uid	session_day	session_month	session_week	session_duration
0	touch	2017-12-20 17:38:00	4	2017-12-20 17:20:00	16879256277535980062	2017-12-20	2017-12-01	2017-12-18	18.000000
1	desktop	2018-02-19 17:21:00	2	2018-02-19 16:53:00	104060357244891740	2018-02-19	2018-02-01	2018-02-19	28.000000
2	touch	2017-07-01 01:54:00	5	2017-07-01 01:54:00	7459035603376831527	2017-07-01	2017-07-01	2017-06-26	0.000000
3	desktop	2018-05-20 11:23:00	9	2018-05-20 10:59:00	16174680259334210214	2018-05-20	2018-05-01	2018-05-14	24.000000

	device	end_ts	source_id	start_ts	uid	session_day	session_month	session_week	session_duration
4	desktop	2017-12-27 14:06:00	3	2017-12-27 14:06:00	9969694820036681168	2017-12-27	2017-12-01	2017-12-25	0.000000
...	...	...	...	...	...	...	...	...	...
359395	desktop	2017-07-29 19:07:19	2	2017-07-29 19:07:00	18362971481961487539	2017-07-29	2017-07-01	2017-07-24	0.316667
359396	touch	2018-01-25 17:38:19	1	2018-01-25 17:38:00	18370831553019119586	2018-01-25	2018-01-01	2018-01-22	0.316667
359397	desktop	2018-03-03 10:12:19	4	2018-03-03 10:12:00	18387297585500748294	2018-03-03	2018-03-01	2018-02-26	0.316667
359398	desktop	2017-11-02 10:12:19	5	2017-11-02 10:12:00	18388616944624776485	2017-11-02	2017-11-01	2017-10-30	0.316667
359399	touch	2017-09-10 13:13:19	2	2017-09-10 13:13:00	18396128934054549559	2017-09-10	2017-09-01	2017-09-04	0.316667

359400 rows × 9 columns

Посмотрим на распределение длительностей сессий по гистограмме.

In [36]:
```
plt.figure(figsize=(15,3));
visits_log['session_duration'].hist(bins=100);
plt.title('Гистограмма длительностей сессий пользователей');
plt.xlabel('Длительность, мин.');
plt.ylabel('Число сессий');
```

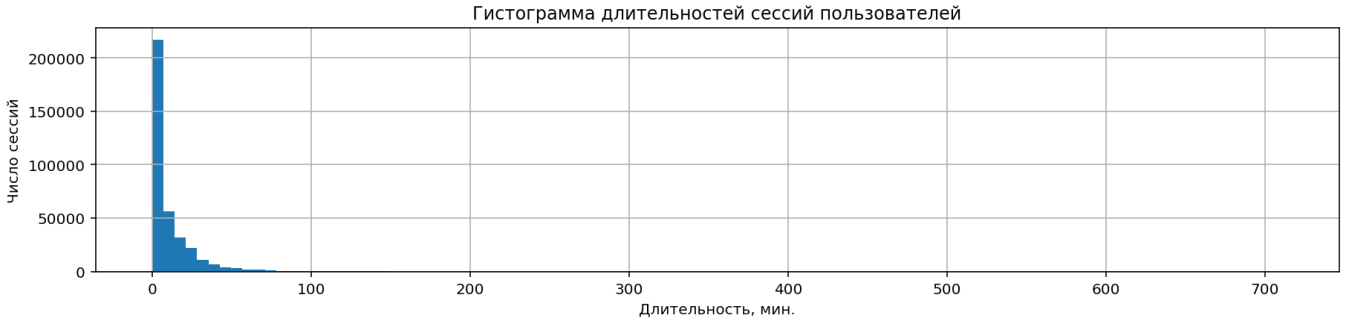

In [37]:
```
visits_log['session_duration'].describe()
```

Out[37]:
```
count    359400.000000
mean         10.717529
std          16.618516
min           0.000000
25%           2.000000
50%           5.000000
75%          14.000000
max         711.000000
Name: session_duration, dtype: float64
```

In [38]:
```
visits_log.groupby('device')['session_duration'].mean()
```

Out[38]:
```
device
desktop    11.722075
touch       7.993657
Name: session_duration, dtype: float64
```

In [39]:
```
visits_log.groupby('device')['session_duration'].median()
```

Out[39]:
```
device
desktop    6.0
touch      3.0
Name: session_duration, dtype: float64
```

In [40]:
```
visits_log['session_duration'].mode()
```

Out[40]:
```
0    1.0
dtype: float64
```

Большинство сессий очень короткие, но есть и длинные. **Наибольшее число сессий с длительностью 1 минута.** По используемым устройствам картина различается:

- Для **настольных систем в среднем длительность 12 минут, по медиане 6 минут**.
- Для **мобильных систем в среднем длительность 8 минут, по медиане 3 минут**.

Для сессий со смартфонов характерны быстрые сессии.

Проверим, сколько есть нулевых сессий.

In [41]:
```
len(visits_log[visits_log['session_duration'] == 0]) /len(visits_log)
```

Out[41]:
```
0.0995937673900946
```

10% данных занимают очень короткие сессии, скорее всего вызванные техническими ошибками при подключении. Для анализа потребуются данные по "настоящим" сессиям не меньше 1 минуты.

In [42]:
```
sessions = visits_log[visits_log['session_duration'] != 0].reset_index()
```

In [43]:
```
sessions
```

Out[43]:

	index	device	end_ts	source_id	start_ts	uid	session_day	session_month	session_week	session_duration
0	0	touch	2017-12-20 17:38:00	4	2017-12-20 17:20:00	16879256277535980062	2017-12-20	2017-12-01	2017-12-18	18.000000
1	1	desktop	2018-02-19 17:21:00	2	2018-02-19 16:53:00	104060357244891740	2018-02-19	2018-02-01	2018-02-19	28.000000
2	3	desktop	2018-05-20 11:23:00	9	2018-05-20 10:59:00	16174680259334210214	2018-05-20	2018-05-01	2018-05-14	24.000000
3	5	desktop	2017-09-03 21:36:00	5	2017-09-03 21:35:00	16007536194108375387	2017-09-03	2017-09-01	2017-08-28	1.000000
4	6	desktop	2018-01-30 12:09:00	1	2018-01-30 11:13:00	6661610529277171451	2018-01-30	2018-01-01	2018-01-29	56.000000
...	...	...	...	...	...	...	...	...	...	...
323601	359395	desktop	2017-07-29 19:07:19	2	2017-07-29 19:07:00	18363291481961487539	2017-07-29	2017-07-01	2017-07-24	0.316667
323602	359396	touch	2018-01-25 17:38:19	1	2018-01-25 17:38:00	18370831553019119586	2018-01-25	2018-01-01	2018-01-22	0.316667
323603	359397	desktop	2018-03-03 10:12:19	4	2018-03-03 10:12:00	18387297585500748294	2018-03-03	2018-03-01	2018-02-26	0.316667
323604	359398	desktop	2017-11-02 10:12:19	5	2017-11-02 10:12:00	18388616944624776485	2017-11-02	2017-11-01	2017-10-30	0.316667
323605	359399	touch	2017-09-10 13:13:19	2	2017-09-10 13:13:00	18396128934054549559	2017-09-10	2017-09-01	2017-09-04	0.316667

323606 rows × 10 columns

In [44]:
```
sessions['session_duration'].describe()
```

Out[44]:
```
count    323606.000000
mean         11.902993
std          17.105912
min           0.316667
25%           2.000000
50%           6.000000
75%          15.000000
max         711.000000
Name: session_duration, dtype: float64
```

Количество уникальных пользователей

Посчитаем сколько сессий и уникальных пользователей есть в месяц, неделю, день.

Посчитаем итоговые метрики DAU, WAU, MAU по числу уникальных пользователей в день, неделю, месяц.

In [45]:
```
DAU = sessions.groupby('session_day')['uid'].nunique().mean()
```

In [46]:
```
DAU
```

Out[46]:
```
817.5851648351648
```

In [47]:
```
WAU = sessions.groupby('session_week')['uid'].nunique().mean()
```

In [48]:
```
WAU
```

Out[48]:
```
5148.301886792453
```

In [49]:
```
MAU = sessions.groupby('session_month')['uid'].nunique().mean()
```

In [50]:
```
MAU
```

Out[50]:
```
20955.75
```

Посчитаем метрику "липкий фактор" по отношению к недельному и месячному показателям.

In [51]:
```
sticky_mau = DAU/MAU*100
```

In [52]:
```
sticky_wau = DAU/WAU*100
```

In [53]:
```
sticky_mau
```

Out[53]:
```
3.9014836731453886
```

In [54]:
```
sticky_wau
```

Out[54]:
```
15.880676440762198
```

Вовлеченнность пользователей (sticky factor) по неделе составляет 16%, что совсем немногим лучше 1/7 = 14%, как если бы каждый день были новые ползователи. Такая же ситуация и по месяцу: 3.9% немногим выше 1/30 = 3.3%. Можно заключить, что аудитория портала постоянно сменяется, только очень малая доля пользователей возвращается.

Проверим эти же показатели по платформам.

In [55]:
```
DAU = sessions.groupby(['device','session_day'])['uid'].nunique().groupby('device').mean().reset_index()
DAU
```

Out[55]:

	device	uid
0	desktop	599.752747
1	touch	221.460055

In [56]:
```
WAU = sessions.groupby(['device','session_week'])['uid'].nunique().groupby('device').mean().reset_index()
WAU
```

Out[56]:

	device	uid
0	desktop	3756.773585
1	touch	1433.981132

In [57]:
```
MAU = sessions.groupby(['device','session_month'])['uid'].nunique().groupby('device').mean().reset_index()
MAU
```

Out[57]:

	device	uid
0	desktop	15239.916667
1	touch	5999.166667

In [58]:
```
DAU.columns = ['device', 'DAU']
WAU.columns = ['device', 'WAU']
MAU.columns = ['device', 'MAU']
```

In [59]:
```
au_metrics = DAU.merge(WAU, on='device').merge(MAU, on='device')
```

In [60]:
```
au_metrics
```

Out[60]:

	device	DAU	WAU	MAU
0	desktop	599.752747	3756.773585	15239.916667
1	touch	221.460055	1433.981132	5999.166667

In [61]:
```
au_metrics['sticky_WAU'] = 100*au_metrics['DAU']/au_metrics['WAU']
```

In [62]:
```
au_metrics['sticky_MAU'] = 100*au_metrics['DAU']/au_metrics['MAU']
```

In [63]:
```
au_metrics
```

Out[63]:

	device	DAU	WAU	MAU	sticky_WAU	sticky_MAU

	device	DAU	WAU	MAU	sticky_WAU	sticky_MAU
0	desktop	599.752747	3756.773585	15239.916667	15.964570	3.935407
1	touch	221.460055	1433.981132	5999.166667	15.443722	3.691514

In [64]:
```
au_metrics[['device','sticky_MAU','sticky_WAU']].plot(kind='bar', grid=True);
plt.title('Вовлеченность пользователей на разных платформах');
plt.ylabel('%');
plt.gca().set_xticklabels(['Настольные системы','Смартфоны']);
```

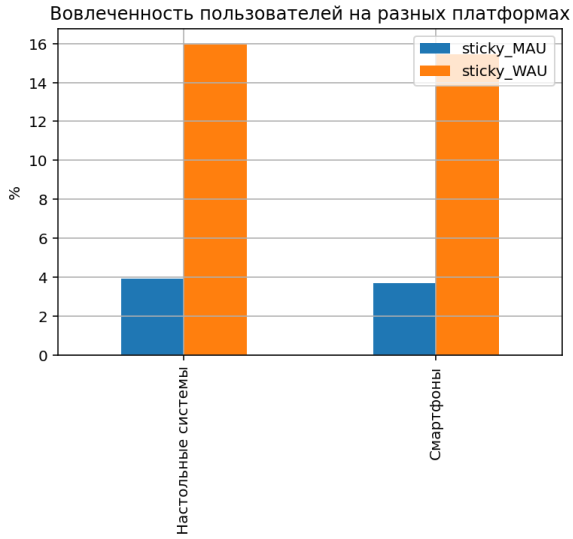

Вовлеченнность пользователей по платформам немного отличается, для настольных систем по недельному показателю 16.0%, для мобильных 15.4%. По месячному показателю 3.9% против 3.7% соотвественно. **Вовлеченность пользователей с настольных систем выше, чем с мобильных устройств.** По-видимому, пользователи настольных систем чаще добавляют сайт в закладки или используют автозаполнение в браузере и таким образом чаще возвращаются на уже посещенные сайты.

Расчитаем также **среднее количество сессий в день**.

In [65]:
```
session_counts = sessions.groupby(['device','session_day'])['uid'].count().groupby('device').mean().reset_index()
```

In [66]:
```
session_counts
```

Out[66]:

	device	uid
0	desktop	656.258242
1	touch	233.410468

In [67]:
```
session_counts.plot(kind='bar', grid=True, legend=False);
plt.ylabel('Сессии в день');
plt.title('Количество сессий в день на разных платформах');
plt.gca().set_xticklabels(['Настольные системы','Смартфоны']);
```

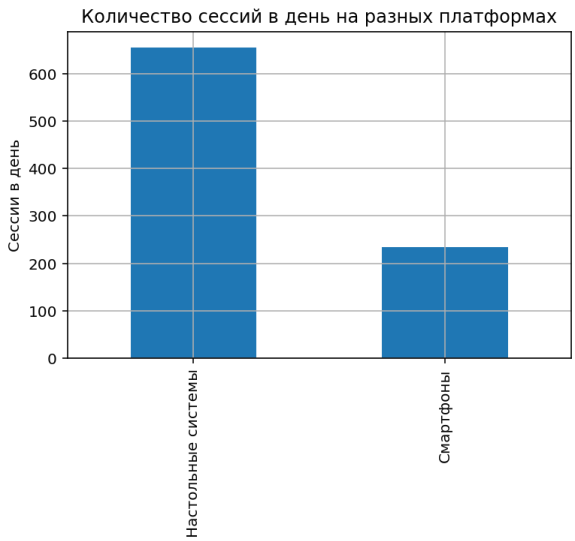

Как количество уникальных пользователей, так и количество сессий в день больше на настольных системах. Вовлеченность пользователей также выше на компьютерах.

Оценка количества возвращающихся пользователей

Посчитаем Retention Rate (коэффициент удержания) и Churn Rate (коэффициент оттока).

Проведем когортный анализ по времени первого визита, используя данные из таблицы `sessions`.

In [68]:
```
sessions.head()
```

Out[68]:

	index	device	end_ts	source_id	start_ts	uid	session_day	session_month	session_week	session_duration
0	0	touch	2017-12-20 17:38:00	4	2017-12-20 17:20:00	16879256277535980062	2017-12-20	2017-12-01	2017-12-18	18.0
1	1	desktop	2018-02-19 17:21:00	2	2018-02-19 16:53:00	104060357244891740	2018-02-19	2018-02-01	2018-02-19	28.0
2	3	desktop	2018-05-20 11:23:00	9	2018-05-20 10:59:00	16174680259334210214	2018-05-20	2018-05-01	2018-05-14	24.0
3	5	desktop	2017-09-03 21:36:00	5	2017-09-03 21:35:00	16007536194108375387	2017-09-03	2017-09-01	2017-08-28	1.0
4	6	desktop	2018-01-30 12:09:00	1	2018-01-30 11:13:00	6661610529277171451	2018-01-30	2018-01-01	2018-01-29	56.0

Выделим даты первого визита для всех пользователей.

In [69]:
```
first_visits = sessions.groupby('uid')['session_day'].min()
```

In [70]:
```
first_visits
```

Out[70]:
```
uid
11863502262781          2018-03-01
49537067089222          2018-02-06
297729379853735         2017-06-07
313578113262317         2017-09-18
325320750514679         2017-09-30
                           ...
18446316582013423015    2018-02-26
18446403737806311543    2017-11-30
18446556406699109058    2018-01-01
18446621818809592527    2017-12-27
18446676030785672386    2017-10-04
Name: session_day, Length: 207051, dtype: datetime64[ns]
```

In [71]:
```
first_visits.name = 'first_session_day'
```

Совместим получившуюся таблицу с изначальной, чтобы создать общий датафрейм.

In [72]:
```
sessions = sessions.merge(first_visits,on='uid')
```

In [73]:
```
sessions['first_session_day'].describe(datetime_is_numeric=True)
```

Out[73]:
```
count                           323606
mean     2017-11-18 01:53:20.536454656
min                2017-06-01 00:00:00
25%                2017-09-07 00:00:00
50%                2017-11-21 00:00:00
75%                2018-02-03 00:00:00
max                2018-05-31 00:00:00
Name: first_session_day, dtype: object
```

В данных собрана информация по визитам за целый год с июня 2017 по июнь 2018, поэтому логично проводить когортный анализ по месяцам первой покупки.

Вычислим отдельно день и месяц первой покупки.

In [74]:
```
sessions['first_session_day'] = sessions['first_session_day'].astype('datetime64[D]')
```

In [75]:
```
sessions['first_session_month'] = sessions['first_session_day'].astype('datetime64[M]')
```

In [76]:
```
sessions.head()
```

Out[76]:

	index	device	end_ts	source_id	start_ts	...	session_month	session_week	session_duration	first_session_day	first_session_month
0	0	touch	2017-12-20 17:38:00	4	2017-12-20 17:20:00	...	2017-12-01	2017-12-18	18.0	2017-12-20	2017-12-01

	index	device	end_ts	source_id	start_ts	...	session_month	session_week	session_duration	first_session_day	first_session_month
1	1	desktop	2018-02-19 17:21:00	2	2018-02-19 16:53:00	...	2018-02-01	2018-02-19	28.0	2018-02-19	2018-02-01
2	3	desktop	2018-05-20 11:23:00	9	2018-05-20 10:59:00	...	2018-05-01	2018-05-14	24.0	2018-03-09	2018-03-01
3	114820	desktop	2018-03-09 20:33:00	4	2018-03-09 20:05:00	...	2018-03-01	2018-03-05	28.0	2018-03-09	2018-03-01
4	5	desktop	2017-09-03 21:36:00	5	2017-09-03 21:35:00	...	2017-09-01	2017-08-28	1.0	2017-09-03	2017-09-01

5 rows × 12 columns

Расчитаем возраст когорты по разнице между месяцем визита и месяцем первого визита.

In [77]:
```
sessions['cohort_lifetime'] = ((sessions['session_day'] - sessions['first_session_day']) \
                               / np.timedelta64(1, 'M')).astype('int')
```

In [78]:
```
sessions.head()
```

Out[78]:

	index	device	end_ts	source_id	start_ts	...	session_week	session_duration	first_session_day	first_session_month	cohort_lifetime
0	0	touch	2017-12-20 17:38:00	4	2017-12-20 17:20:00	...	2017-12-18	18.0	2017-12-20	2017-12-01	0
1	1	desktop	2018-02-19 17:21:00	2	2018-02-19 16:53:00	...	2018-02-19	28.0	2018-02-19	2018-02-01	0
2	3	desktop	2018-05-20 11:23:00	9	2018-05-20 10:59:00	...	2018-05-14	24.0	2018-03-09	2018-03-01	2
3	114820	desktop	2018-03-09 20:33:00	4	2018-03-09 20:05:00	...	2018-03-05	28.0	2018-03-09	2018-03-01	0
4	5	desktop	2017-09-03 21:36:00	5	2017-09-03 21:35:00	...	2017-08-28	1.0	2017-09-03	2017-09-01	0

5 rows × 13 columns

Расчитаем сколько визитов совершают пользователи в каждой когорте.

In [79]:
```
cohorts = sessions.groupby(['device','first_session_month','cohort_lifetime'])['uid'].nunique().reset_index()
```

In [80]:
```
cohorts = cohorts.rename(columns={'uid':'n_users'})
```

In [81]:
```
cohorts
```

Out[81]:

	device	first_session_month	cohort_lifetime	n_users
0	desktop	2017-06-01	0	8856
1	desktop	2017-06-01	1	556
2	desktop	2017-06-01	2	528
3	desktop	2017-06-01	3	631
4	desktop	2017-06-01	4	638
...	...	...	...	...
151	touch	2018-03-01	1	150
152	touch	2018-03-01	2	86
153	touch	2018-04-01	0	4401
154	touch	2018-04-01	1	67
155	touch	2018-05-01	0	4557

156 rows × 4 columns

In [82]:
```
initial_users_count = cohorts[cohorts['cohort_lifetime'] == 0][['device','first_session_month', 'n_users']]
```

In [83]:
```
initial_users_count.columns = ['device','first_session_month', 'cohort_users']
```

In [84]:
```
cohorts = cohorts.merge(initial_users_count, on=['device','first_session_month'])
```

In [85]:
```
cohorts['retention'] = cohorts['n_users'] / cohorts['cohort_users']
```

In [86]:
```
retention = cohorts.pivot_table(
    index='first_session_month',
    columns='cohort_lifetime',
    values='retention',
    aggfunc='mean')
```

In [87]:
```
retention
```

Out[87]:

cohort_lifetime	0	1	2	3	4	...	7	8	9	10	11
first_session_month											
2017-06-01	1.0	0.052179	0.050598	0.059982	0.060998	...	0.050979	0.051543	0.044065	0.037644	0.031972
2017-07-01	1.0	0.047120	0.052530	0.052280	0.052655	...	0.041684	0.029010	0.025541	0.017085	NaN
2017-08-01	1.0	0.056864	0.058334	0.053407	0.039752	...	0.028936	0.023571	0.012016	NaN	NaN
2017-09-01	1.0	0.063826	0.060801	0.038685	0.036997	...	0.022777	0.010165	NaN	NaN	NaN
2017-10-01	1.0	0.058966	0.043392	0.035507	0.031964	...	0.009719	NaN	NaN	NaN	NaN
2017-11-01	1.0	0.050818	0.039495	0.035215	0.025694	...	NaN	NaN	NaN	NaN	NaN
2017-12-01	1.0	0.044508	0.033703	0.023469	0.019013	...	NaN	NaN	NaN	NaN	NaN
2018-01-01	1.0	0.041337	0.027720	0.020732	0.008611	...	NaN	NaN	NaN	NaN	NaN
2018-02-01	1.0	0.034391	0.020828	0.009867	NaN	...	NaN	NaN	NaN	NaN	NaN
2018-03-01	1.0	0.029057	0.014041	NaN	NaN	...	NaN	NaN	NaN	NaN	NaN
2018-04-01	1.0	0.018055	NaN	NaN	NaN	...	NaN	NaN	NaN	NaN	NaN
2018-05-01	1.0	NaN	NaN	NaN	NaN	...	NaN	NaN	NaN	NaN	NaN

12 rows × 12 columns

In [88]:
```
sns.set(style='white');
plt.figure(figsize=(13, 9));
plt.title('Коэффициент удержания по когортам');
sns.heatmap(retention, annot=True, fmt='.1%', linewidths=1, linecolor='gray');
plt.xlabel('Время жизни когорты');
plt.ylabel('Когорта');
```

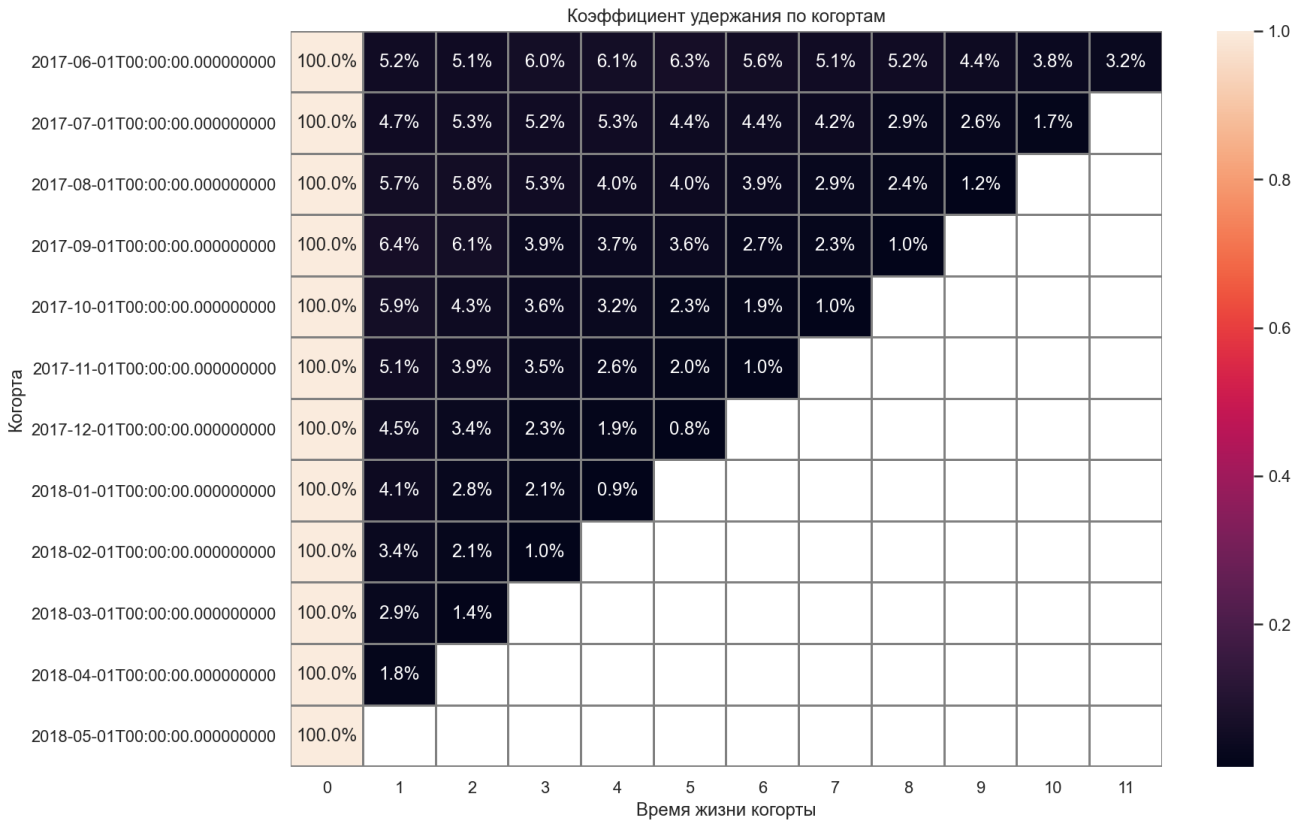

Если исключить первый столбец, различия в следующие периоды будут более явные.

In [89]:
```
sns.set(style='white');
plt.figure(figsize=(13, 9));
plt.title('Коэффициент удержания по когортам');
sns.heatmap(retention.drop(columns=0, axis=1), annot=True, fmt='.1%', linewidths=1, linecolor='gray');
plt.xlabel('Время жизни когорты');
plt.ylabel('Когорта');
```

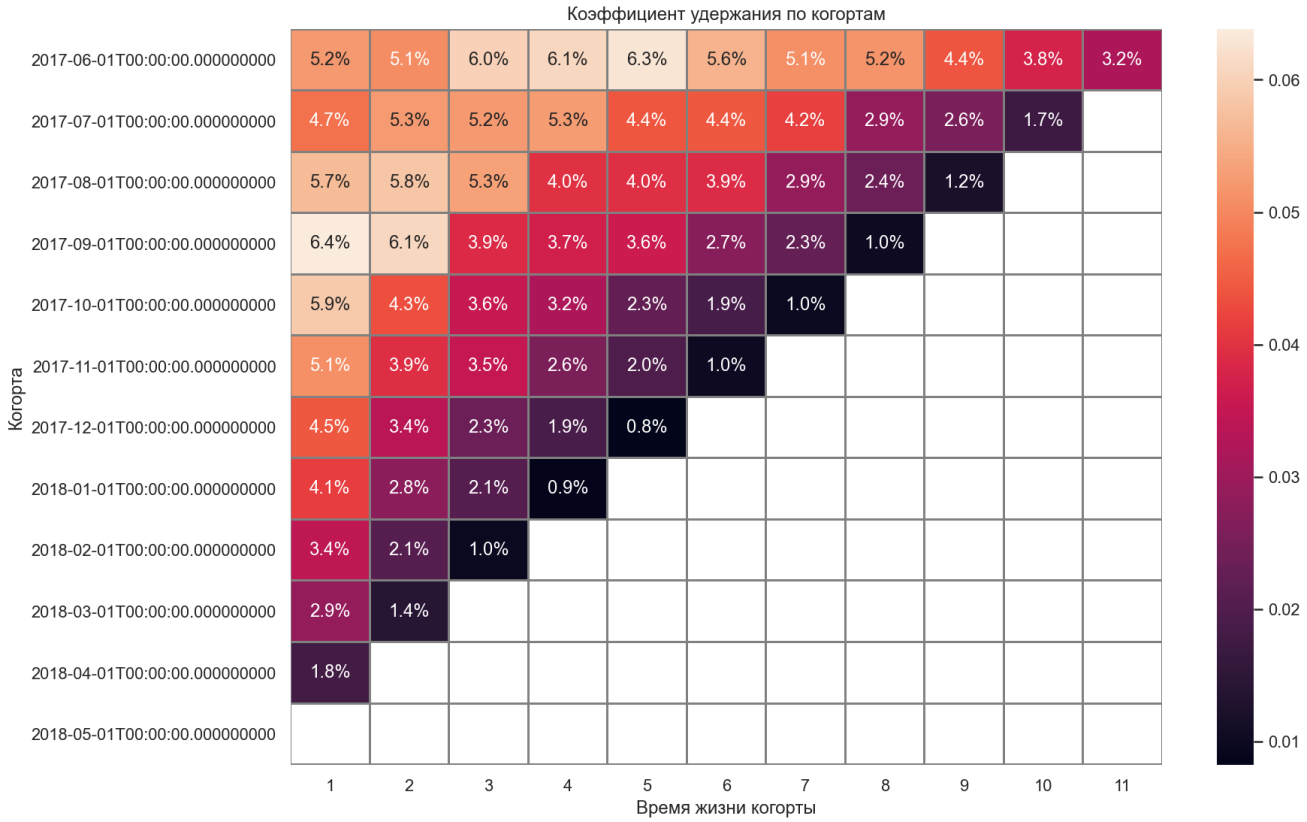

Как видно, очень мало пользователей возвращаются на портал по всем источникам. Больше всего пользователей осталось из самой первой когорты - 3.2%.

Посмотрим по устройствам.

In [90]:
```
retention_desktop = cohorts.query('device == "desktop"').pivot_table(
    index='first_session_month',
    columns='cohort_lifetime',
    values='retention',
    aggfunc='mean')
```

In [91]:
```
retention_touch = cohorts.query('device == "touch"').pivot_table(
    index='first_session_month',
    columns='cohort_lifetime',
    values='retention',
    aggfunc='mean')
```

In [92]:
```
sns.set(style='white');
plt.figure(figsize=(13, 9));
plt.title('Коэффициент удержания по когортам для настольных систем');
sns.heatmap(retention_desktop.drop(columns=0, axis=1), annot=True, fmt='.1%', linewidths=1, linecolor='gray');
plt.xlabel('Время жизни когорты');
plt.ylabel('Когорта');
```

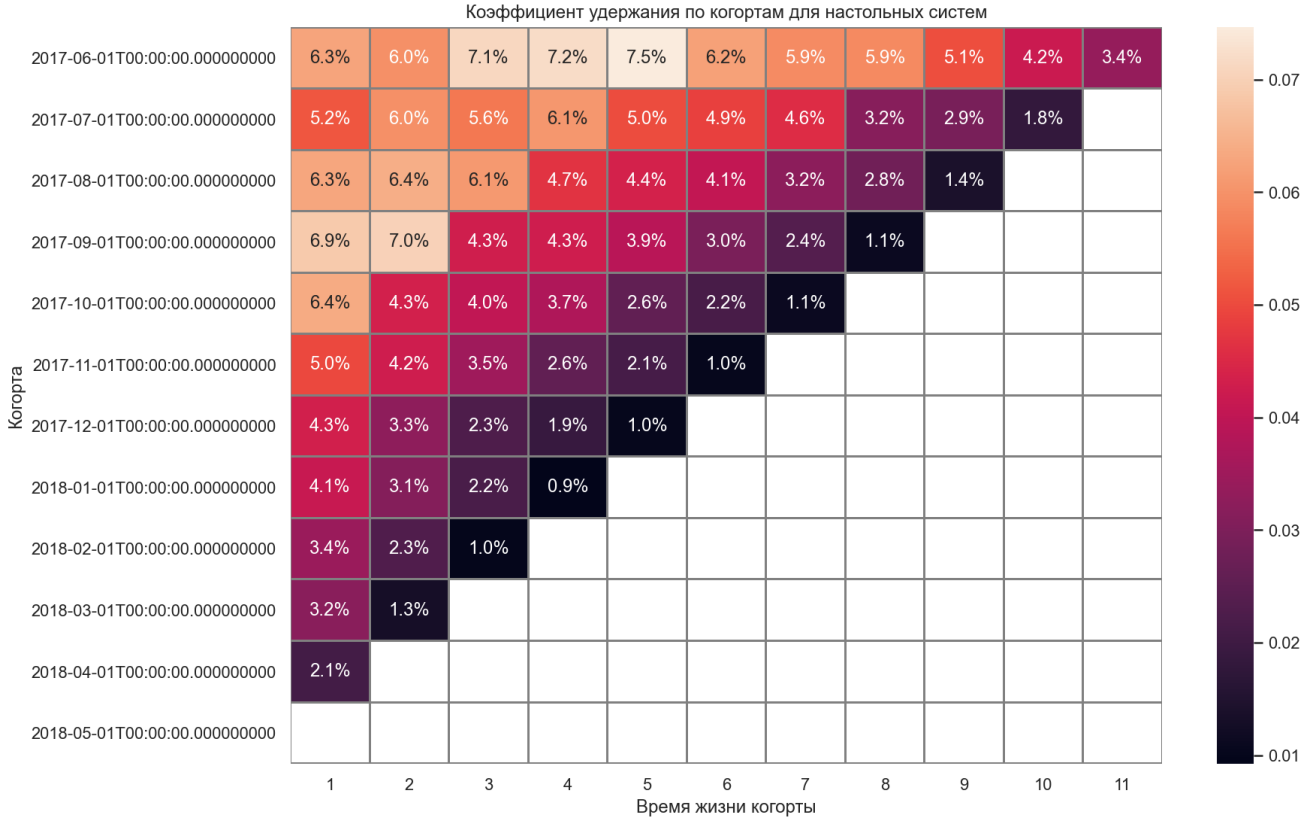

In [93]:
```
sns.set(style='white');
plt.figure(figsize=(13, 9));
plt.title('Коэффициент удержания по когортам для смартфонов');
sns.heatmap(retention_touch.drop(columns=0, axis=1), annot=True, fmt='.1%', linewidths=1, linecolor='gray');
plt.xlabel('Время жизни когорты');
plt.ylabel('Когорта');
```

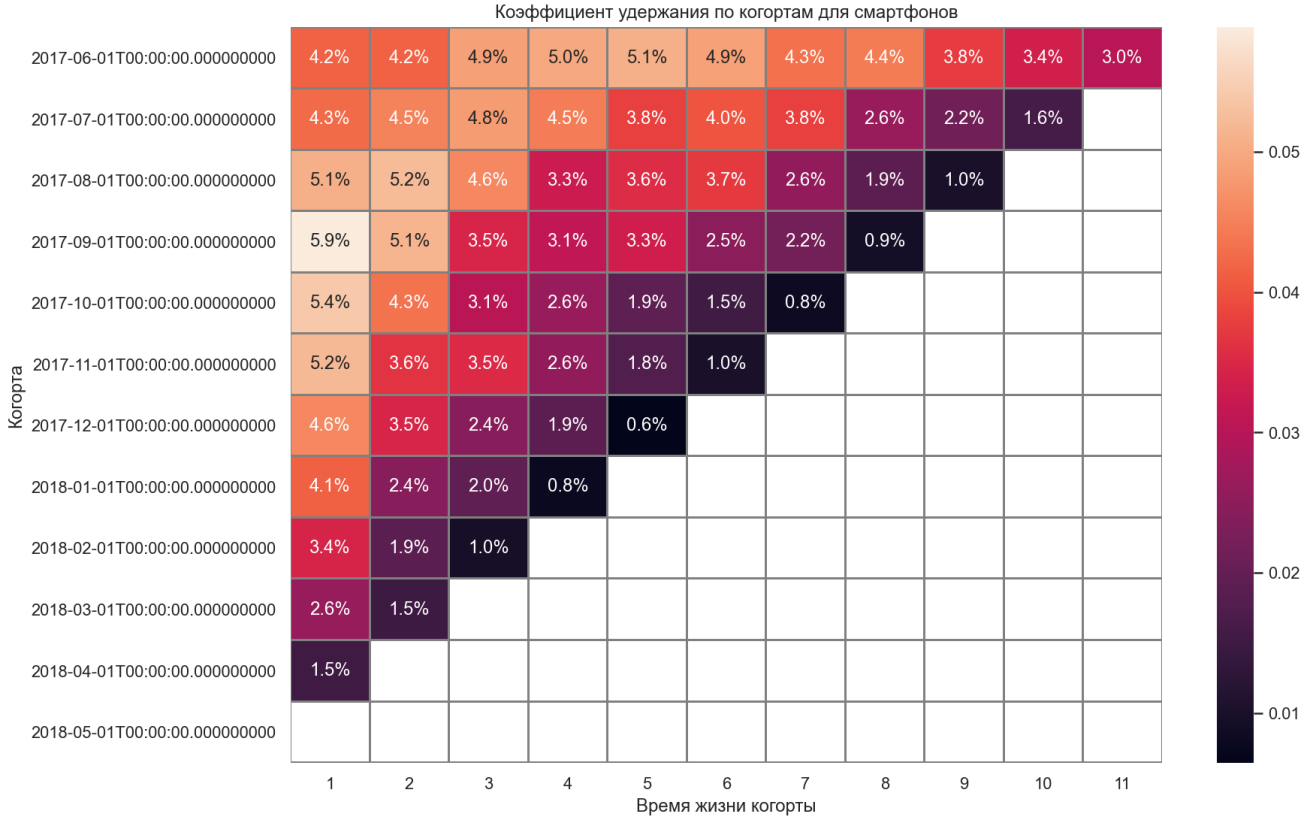

Как видно, после первого месяца остается на настольных системах всего 6% пользователей, для смартфонов еще меньше - 4%. В сентябре 2019 года для платформ заметно, что осталось больше пользователей во второй месяц (для смартфонов) и второй-третий месяц (для настольных систем). Возможно, это связано с маркетиновыми акциями или другими факторами, которые пришлись на этот период.

Рассчитаем коэффициент оттока клиентов.

In [94]:
```
cohorts_desktop = cohorts.query('device == "desktop"')
cohorts_touch = cohorts.query('device == "touch"')
```

In [95]:
```
cohorts['churn_desktop'] = cohorts_desktop.groupby('first_session_month')['n_users'].pct_change()
cohorts['churn_touch'] = cohorts_touch.groupby('first_session_month')['n_users'].pct_change()
```

In [96]:
```
churn_desktop = cohorts.pivot_table(
    index='first_session_month',
    columns='cohort_lifetime',
    values='churn_desktop',
    aggfunc='mean')
churn_touch = cohorts.pivot_table(
    index='first_session_month',
    columns='cohort_lifetime',
    values='churn_touch',
    aggfunc='mean')
```

In [97]:
```
churn_desktop
```

Out[97]:

cohort_lifetime	1	2	3	4	5	...	7	8	9	10	11
first_session_month											
2017-06-01	-0.937218	-0.050360	0.195076	0.011094	0.036050	...	-0.054446	-0.001919	-0.138462	-0.174107	-0.197297
2017-07-01	-0.948440	0.159817	-0.061024	0.079665	-0.170874	...	-0.062954	-0.304910	-0.074349	-0.381526	NaN
2017-08-01	-0.936961	0.020882	-0.052273	-0.235012	-0.065831	...	-0.205036	-0.131222	-0.505208	NaN	NaN
2017-09-01	-0.931223	0.020243	-0.390212	-0.002169	-0.086957	...	-0.200627	-0.529412	NaN	NaN	NaN
2017-10-01	-0.936161	-0.320667	-0.068213	-0.073206	-0.309637	...	-0.485014	NaN	NaN	NaN	NaN
2017-11-01	-0.950352	-0.144095	-0.173418	-0.266462	-0.169102	...	NaN	NaN	NaN	NaN	NaN
2017-12-01	-0.956890	-0.241473	-0.307554	-0.163636	-0.468944	...	NaN	NaN	NaN	NaN	NaN
2018-01-01	-0.958608	-0.247508	-0.295806	-0.576803	NaN	...	NaN	NaN	NaN	NaN	NaN
2018-02-01	-0.965666	-0.334008	-0.562310	NaN	NaN	...	NaN	NaN	NaN	NaN	NaN
2018-03-01	-0.968050	-0.590588	NaN	NaN	NaN	...	NaN	NaN	NaN	NaN	NaN
2018-04-01	-0.979114	NaN	NaN	NaN	NaN	...	NaN	NaN	NaN	NaN	NaN

11 rows × 11 columns

In [98]:
```
churn_touch
```

Out[98]:

cohort_lifetime	1	2	3	4	5	...	7	8	9	10	11
first_session_month											
2017-06-01	-0.958424	0.000000	0.171642	0.025478	0.018634	...	-0.120253	0.028777	-0.153846	-0.107438	-0.092593
2017-07-01	-0.957319	0.060403	0.069620	-0.076923	-0.147436	...	-0.057143	-0.303030	-0.173913	-0.263158	NaN
2017-08-01	-0.949311	0.032000	-0.124031	-0.283186	0.086420	...	-0.315217	-0.253968	-0.468085	NaN	NaN
2017-09-01	-0.941125	-0.126394	-0.327660	-0.094937	0.069930	...	-0.115044	-0.580000	NaN	NaN	NaN
2017-10-01	-0.945907	-0.197368	-0.295082	-0.134884	-0.274194	...	-0.462963	NaN	NaN	NaN	NaN
2017-11-01	-0.948011	-0.297994	-0.032653	-0.274262	-0.308140	...	NaN	NaN	NaN	NaN	NaN
2017-12-01	-0.954094	-0.243986	-0.300000	-0.214286	-0.661157	...	NaN	NaN	NaN	NaN	NaN
2018-01-01	-0.958717	-0.411538	-0.196078	-0.593496	NaN	...	NaN	NaN	NaN	NaN	NaN
2018-02-01	-0.965551	-0.454545	-0.482456	NaN	NaN	...	NaN	NaN	NaN	NaN	NaN
2018-03-01	-0.973836	-0.426667	NaN	NaN	NaN	...	NaN	NaN	NaN	NaN	NaN
2018-04-01	-0.984776	NaN	NaN	NaN	NaN	...	NaN	NaN	NaN	NaN	NaN

11 rows × 11 columns

In [99]:
```
sns.set(style='white');
plt.figure(figsize=(13, 9));
plt.title('Коэффициент оттока клиентов по когортам для настольных систем');
sns.heatmap(churn_desktop, annot=True, fmt='.1%', linewidths=1, linecolor='gray');
plt.xlabel('Время жизни когорты');
plt.ylabel('Когорта');
```

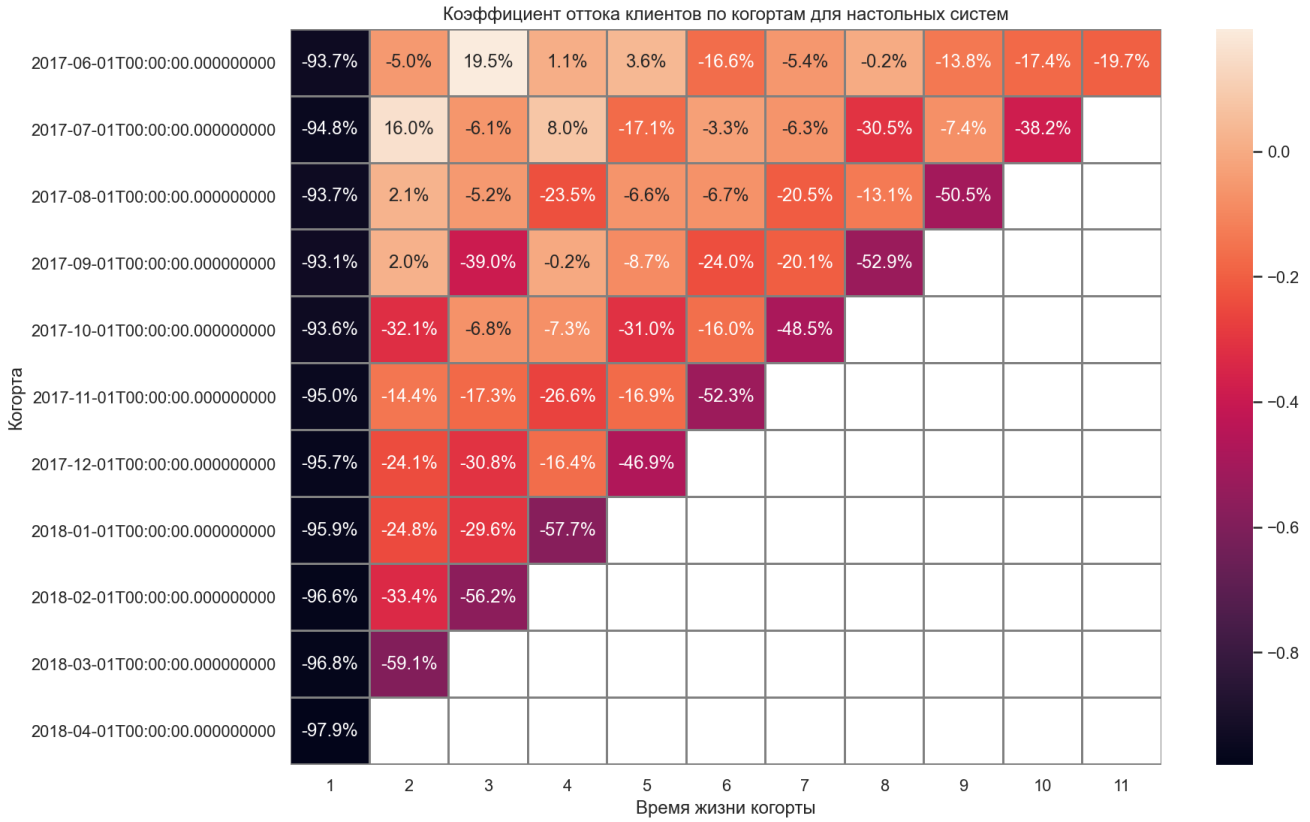

In [100…

```
sns.set(style='white');
plt.figure(figsize=(13, 9));
plt.title('Коэффициент оттока клиентов по когортам для смартфонов');
sns.heatmap(churn_touch, annot=True, fmt='.1%', linewidths=1, linecolor='gray');
plt.xlabel('Время жизни когорты');
plt.ylabel('Когорта');
```

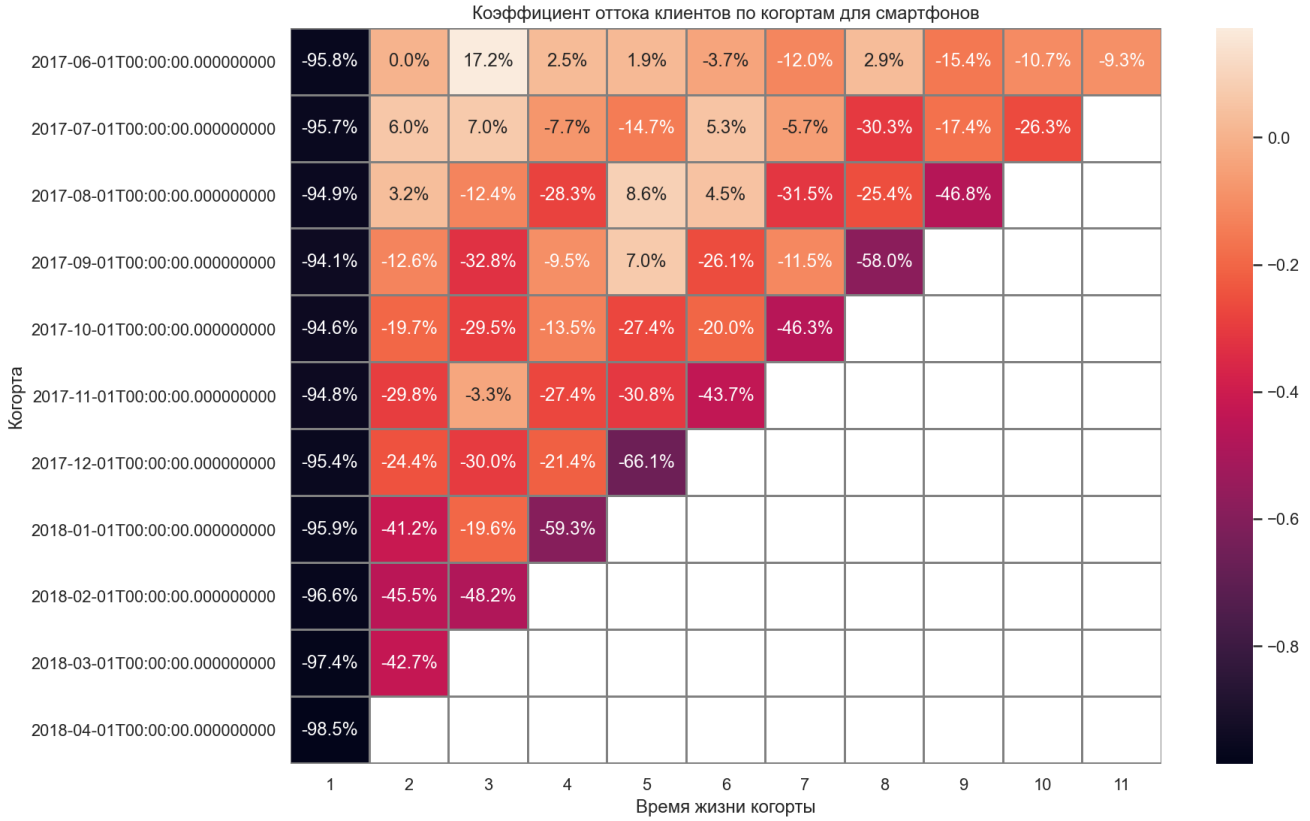

Расчеты метрик оттока клиентов показывают, что после первого месяца на обеих платформах остается всего около 5-7% пользователей, а их число потом также спадает. В последнем периоде отток клиентов наибольший (от 40% до 60%). Для первой когорты характерен рост числа пользователей на третий месяц в размере 17%-19%, что соответствует сентябрю 2017 года, где мы ранее отмечали меньший отток клиентов. Возможно, маркетинговые акции не только способствовали удержанию новых клиентов, но

и вернули тех, кто ранее уже пользовался продуктом. Также можно отметить, что более новые когорты показывают даже больший отток, чем более старые, для них наблюдается сильный отток уже со второго-третьего месяца. Для последней когорты в анализе отток пользователей уже на второй месяц составил внушительные 98% для всех платформ, что сильно хуже первой когорты с показателем 94%-95%.

Расчет метрик продаж

- Когда люди начинают покупать?
- Сколько раз покупают за период?
- Какой средний чек?
- Сколько денег приносят? (LTV)

Для ответа на вопрос "Когда люди начинают покупать?" выделим из таблицы с сесииями для каждого пользователя дату визита, а затем совметим ее с таблицей заказов по `uid` .

In [101…
```
sessions.head()
```

Out[101…

	index	device	end_ts	source_id	start_ts	...	session_week	session_duration	first_session_day	first_session_month	cohort_lifetime
0	0	touch	2017-12-20 17:38:00	4	2017-12-20 17:20:00	...	2017-12-18	18.0	2017-12-20	2017-12-01	0
1	1	desktop	2018-02-19 17:21:00	2	2018-02-19 16:53:00	...	2018-02-19	28.0	2018-02-19	2018-02-01	0
2	3	desktop	2018-05-20 11:23:00	9	2018-05-20 10:59:00	...	2018-05-14	24.0	2018-03-09	2018-03-01	2
3	114820	desktop	2018-03-09 20:33:00	4	2018-03-09 20:05:00	...	2018-03-05	28.0	2018-03-09	2018-03-01	0
4	5	desktop	2017-09-03 21:36:00	5	2017-09-03 21:35:00	...	2017-08-28	1.0	2017-09-03	2017-09-01	0

5 rows × 13 columns

In [102…
```
sessions_users = sessions[['uid', 'device', 'source_id','session_day']]
```

In [103…
```
sessions_users.head()
```

Out[103…

	uid	device	source_id	session_day
0	16879256277535980062	touch	4	2017-12-20
1	104060357244891740	desktop	2	2018-02-19
2	16174680259334210214	desktop	9	2018-05-20
3	16174680259334210214	desktop	4	2018-03-09
4	16007536194108375387	desktop	5	2017-09-03

In [104…
```
orders_log.head()
```

Out[104…

	buy_ts	revenue	uid
0	2017-06-01 00:10:00	17.00	10329302124590727494
1	2017-06-01 00:25:00	0.55	11627257723692907447
2	2017-06-01 00:27:00	0.37	17903680561304213844
3	2017-06-01 00:29:00	0.55	16109239769442553005
4	2017-06-01 07:58:00	0.37	14200605875248379450

In [105…
```
orders_users = orders_log[['uid','buy_ts']]
```

In [106…
```
orders_users['order_date'] = orders_users['buy_ts'].astype('datetime64[D]')
```

In [107…
```
orders_users.head()
```

Out[107…

	uid	buy_ts	order_date
0	10329302124590727494	2017-06-01 00:10:00	2017-06-01
1	11627257723692907447	2017-06-01 00:25:00	2017-06-01
2	17903680561304213844	2017-06-01 00:27:00	2017-06-01

	uid	buy_ts	order_date
3	16109239769442553005	2017-06-01 00:29:00	2017-06-01
4	14200605875248379450	2017-06-01 07:58:00	2017-06-01

Совместим таблицу визитов с заказами по пользователям, исходя из предположения, что заказ сопровождается визитом и их даты совпадают. Таким образом мы сможем получить данные с какого устройства и из какого источника пришел пользователь в первый раз и когда совершил покупку.

In [108…
```
users_report = sessions_users.merge(orders_users,
                                    left_on=['uid','session_day'],
                                    right_on=['uid','order_date'],
                                    how='left')
```

Колонка с временем заказа не нужна.

In [109…
```
users_report = users_report.drop(columns=['buy_ts'])
```

In [110…
```
users_report.head()
```

Out[110…

	uid	device	source_id	session_day	order_date
0	16879256277535980062	touch	4	2017-12-20	NaT
1	104060357244891740	desktop	2	2018-02-19	NaT
2	16174680259334210214	desktop	9	2018-05-20	NaT
3	16174680259334210214	desktop	4	2018-03-09	2018-03-09
4	16007536194108375387	desktop	5	2017-09-03	NaT

Теперь в одной таблице собрана информация о том, когда были визиты и был ли заказ при этом визите.

Проверим на конкретном пользователе.

In [111…
```
users_report[users_report['uid'] == 5081614443770358]
```

Out[111…

	uid	device	source_id	session_day	order_date
208447	5081614443770358	desktop	3	2017-11-13	2017-11-13
208448	5081614443770358	desktop	3	2017-10-20	NaT
208449	5081614443770358	desktop	5	2017-11-13	2017-11-13
208450	5081614443770358	desktop	4	2018-02-26	NaT
208451	5081614443770358	desktop	9	2018-01-08	NaT

Так как нельзя понять по предоставленным данным, откуда пришел пользователь, если он в течение дня заходил из 2 источников (3 и 5), в таблице заказ был отмечен для каждого источника.

Теперь сгруппируем данные по пользователю, устройству и источнику по времени первого заказа и первой покупке.

In [112…
```
users_report_pivot = users_report.groupby(['uid','device','source_id'])[['session_day','order_date']] \
                                 .agg({'session_day':'min', 'order_date':'min'})
```

In [113…
```
users_report_pivot = users_report_pivot.reset_index()
```

In [114…
```
users_report_pivot.head()
```

Out[114…

	uid	device	source_id	session_day	order_date
0	11863502262781	touch	3	2018-03-01	NaT
1	49537067089222	touch	2	2018-02-06	NaT
2	297729379853735	desktop	3	2017-06-07	NaT
3	313578113262317	desktop	2	2017-09-18	NaT
4	325320750514679	desktop	5	2017-09-30	NaT

In [115…
```
users_report_pivot[users_report_pivot['uid'] == 5081614443770358]
```

Out[115…

	uid	device	source_id	session_day	order_date
69	5081614443770358	desktop	3	2017-10-20	2017-11-13

	uid	device	source_id	session_day	order_date
70	5081614443770358	desktop	4	2018-02-26	NaT
71	5081614443770358	desktop	5	2017-11-13	2017-11-13
72	5081614443770358	desktop	9	2018-01-08	NaT

Таким образом в получившейся сводной таблице для каждого источника и устройства есть данные о первом заказе и первом визите. Расчитаем задержку между визитом и заказом.

In [116…
```
users_report_pivot['buy_delay'] = (users_report_pivot['order_date'] - users_report_pivot['session_day']) \
                                  / np.timedelta64(1, 'D')
```

In [117…
```
users_report_pivot.head()
```

Out[117…

	uid	device	source_id	session_day	order_date	buy_delay
0	11863502262781	touch	3	2018-03-01	NaT	NaN
1	49537067089222	touch	2	2018-02-06	NaT	NaN
2	297729379853735	desktop	3	2017-06-07	NaT	NaN
3	313578113262317	desktop	2	2017-09-18	NaT	NaN
4	325320750514679	desktop	5	2017-09-30	NaT	NaN

In [118…
```
users_report_pivot['buy_delay'].describe()
```

Out[118…
```
count    37662.000000
mean         4.891270
std         25.963936
min          0.000000
25%          0.000000
50%          0.000000
75%          0.000000
max        357.000000
Name: buy_delay, dtype: float64
```

Как видно по данным, подавляющее большинство заказов совершается в день первого визита, посмотроим еще одну сводную таблицу, чтобы узнать как это различается для разных источников трафика.

In [119…
```
users_report_pivot.pivot_table(index='source_id',
                               columns='device',
                               values='buy_delay',
                               aggfunc=['count','max','mean','median','min'],
                               dropna=False)
```

Out[119…

	count		max		mean		median		min	
device	**desktop**	**touch**	**desktop**	**touch**	**desktop**	**touch**	**desktop**	**touch**	**desktop**	**touch**
source_id										
1	4035	1104	347.0	308.0	3.756382	3.884964	0.0	0.0	0.0	0.0
2	3523	1027	345.0	270.0	9.451036	6.306719	0.0	0.0	0.0	0.0
3	7602	1317	336.0	240.0	4.399369	1.950645	0.0	0.0	0.0	0.0
4	7625	1978	352.0	343.0	5.272525	5.068251	0.0	0.0	0.0	0.0
5	6179	1073	344.0	176.0	2.830393	1.744641	0.0	0.0	0.0	0.0
6	0	0	NaN	NaN	NaN	NaN	NaN	NaN	NaN	NaN
7	1	0	0.0	NaN	0.000000	NaN	0.0	NaN	0.0	NaN
9	797	153	294.0	251.0	18.324969	10.581699	0.0	0.0	0.0	0.0
10	1002	246	357.0	182.0	2.729541	1.768293	0.0	0.0	0.0	0.0

In [120…
```
len(users_report_pivot[users_report_pivot['buy_delay'] == 0]) / len(users_report_pivot.dropna())
```

Out[120…
```
0.9065370930911795
```

В 90% случаев заказ происходит в тот же день. По сводной таблице выше видно, что по 6 источнику не было совершено ни одного заказа, а по 7 источнику заказ был, но только с настольной платформы. Несмотря на то, что большинство заказов по медиане совершались в тот же день, по среднему можно сделать вывод, что быстрее всего с настольных систем в среднем совершали заказ на 2-3 день пользователи из источника 5, далее источники 1, 10, 3, 4 и 2. В среднем заказс мобильных устройств совершался на 2-3 день

для всех источников. Также видно, что покупки по времени для источника 1 практически равны для настольных и мобильных систем, поэтому источник 1 можно считать универсальным по платформам.

Проведем когортный анализ по времени первой покупки, используя данные из таблицы `orders_log` .

In [121…
```
orders_log.head()
```

Out[121…

	buy_ts	revenue	uid
0	2017-06-01 00:10:00	17.00	10329302124590727494
1	2017-06-01 00:25:00	0.55	11627257723692907447
2	2017-06-01 00:27:00	0.37	17903680561304213844
3	2017-06-01 00:29:00	0.55	16109239769442553005
4	2017-06-01 07:58:00	0.37	14200605875248379450

Выделим даты первой покупки для всех пользователей.

In [122…
```
first_orders = orders_log.groupby('uid')['buy_ts'].min()
```

In [123…
```
first_orders
```

Out[123…
```
uid
313578113262317         2018-01-03 21:51:00
1575281904278712        2017-06-03 10:13:00
2429014661409475        2017-10-11 18:33:00
2464366381792757        2018-01-28 15:54:00
2551852515556206        2017-11-24 10:14:00
                                ...
18445147675727495770    2017-11-24 09:03:00
18445407535914413204    2017-09-22 23:55:00
18445601152732270159    2018-03-26 22:54:00
18446156210226471712    2018-02-18 19:34:00
18446167067214817906    2017-10-17 10:16:00
Name: buy_ts, Length: 36523, dtype: datetime64[ns]
```

In [124…
```
first_orders.name = 'first_order_day'
```

Совместим получившуюся таблицу с изначальной, чтобы создать общий датафрейм.

In [125…
```
orders_activity = orders_log.merge(first_orders,on='uid')
```

In [126…
```
orders_activity['first_order_day'].describe(datetime_is_numeric=True)
```

Out[126…
```
count                           50415
mean     2017-11-30 19:10:17.995834368
min                2017-06-01 00:10:00
25%                2017-09-26 17:18:30
50%                2017-11-30 14:09:00
75%                2018-02-14 16:43:30
max                2018-06-01 00:02:00
Name: first_order_day, dtype: object
```

В данных собрана информация по заказам за целый год с июня 2017 по июнь 2018, поэтому логично проводить когортный анализ по месяцам первой покупки.

Вычислим отдельно день и месяц первой покупки.

In [127…
```
orders_activity['first_order_day'] = orders_activity['first_order_day'].astype('datetime64[D]')
```

In [128…
```
orders_activity['first_order_month'] = orders_activity['first_order_day'].astype('datetime64[M]')
```

In [129…
```
orders_activity
```

Out[129…

	buy_ts	revenue	uid	first_order_day	first_order_month
0	2017-06-01 00:10:00	17.00	10329302124590727494	2017-06-01	2017-06-01
1	2017-06-01 00:25:00	0.55	11627257723692907447	2017-06-01	2017-06-01
2	2017-06-01 00:27:00	0.37	17903680561304213844	2017-06-01	2017-06-01
3	2017-06-01 00:29:00	0.55	16109239769442553005	2017-06-01	2017-06-01
4	2017-06-01 07:58:00	0.37	14200605875248379450	2017-06-01	2017-06-01
...	...	...	...	...	...
50410	2018-05-31 23:50:00	4.64	12296626599487328624	2018-05-31	2018-05-01

	buy_ts	revenue	uid	first_order_day	first_order_month
50411	2018-05-31 23:50:00	5.80	11369640365507475976	2018-05-31	2018-05-01
50412	2018-05-31 23:54:00	0.30	1786462140797698849	2018-05-31	2018-05-01
50413	2018-05-31 23:56:00	3.67	3993697860786194247	2018-05-31	2018-05-01
50414	2018-06-01 00:02:00	3.42	83872787173869366	2018-06-01	2018-06-01

50415 rows × 5 columns

Расчитаем время возраст когорты по разнице между месяцем заказа и месяцем первого заказа.

In [130…
```
orders_activity['cohort_lifetime'] = ((orders_activity['buy_ts'] - orders_activity['first_order_day']) \
                                      / np.timedelta64(1, 'M')).astype('int')
```

In [131…
```
orders_activity.head()
```

Out[131…

	buy_ts	revenue	uid	first_order_day	first_order_month	cohort_lifetime
0	2017-06-01 00:10:00	17.00	10329302124590727494	2017-06-01	2017-06-01	0
1	2017-06-01 00:25:00	0.55	11627257723692907447	2017-06-01	2017-06-01	0
2	2017-06-01 00:27:00	0.37	17903680561304213844	2017-06-01	2017-06-01	0
3	2017-06-01 00:29:00	0.55	16109239769442553005	2017-06-01	2017-06-01	0
4	2017-06-01 07:58:00	0.37	14200605875248379450	2017-06-01	2017-06-01	0

Расчитаем сколько покупок совершают пользователи по месяцам с помощью когортного анализа.

In [132…
```
cohorts = orders_activity.groupby(['first_order_month','cohort_lifetime'])['uid'].count().reset_index()
```

In [133…
```
cohorts.rename(columns={'uid':'orders_num'}, inplace=True)
```

In [134…
```
cohorts
```

Out[134…

	first_order_month	cohort_lifetime	orders_num
0	2017-06-01	0	2414
1	2017-06-01	1	157
2	2017-06-01	2	167
3	2017-06-01	3	275
4	2017-06-01	4	265
…	…	…	…
74	2018-03-01	2	84
75	2018-04-01	0	2608
76	2018-04-01	1	82
77	2018-05-01	0	3249
78	2018-06-01	0	1

79 rows × 3 columns

In [135…
```
orders_pivot = cohorts.pivot_table(
    index='first_order_month',
    columns='cohort_lifetime',
    values='orders_num',
    aggfunc='sum')
```

In [136…
```
sns.set(style='white');
plt.figure(figsize=(13, 9));
plt.title('Количество заказов клиентов по когортам');
sns.heatmap(orders_pivot, annot=True, fmt='.0f', linewidths=1, linecolor='gray');
plt.xlabel('Время жизни когорты');
plt.ylabel('Когорта');
```

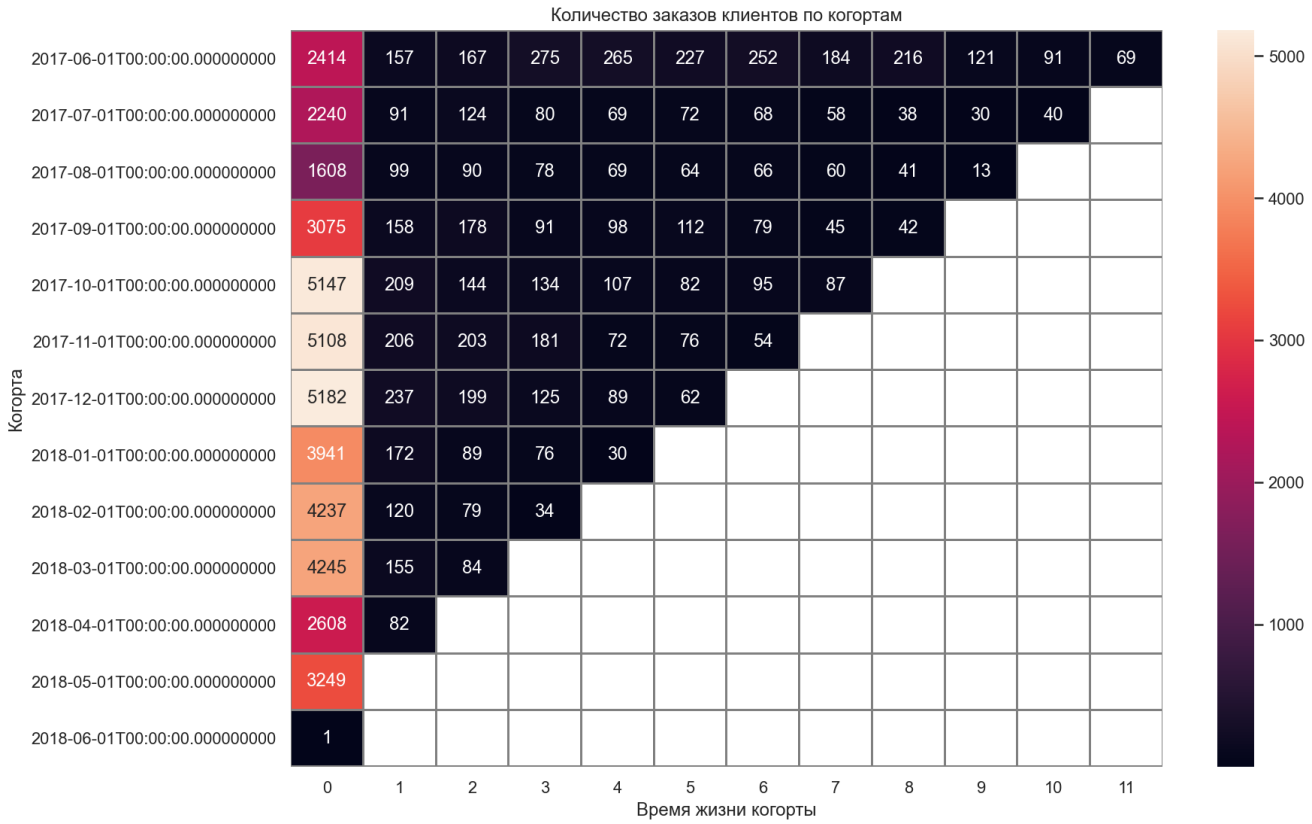

Больше всего заказов было совершено в декабре 2017 года, а также в октябре и ноябре. Меньше всего заказов совершили в августе. Количество заказов по когортам уменьшалось в следующие периоды и было на порядок меньше, чем в первый период.

Расчитаем валовые продажи по когортам.

Посчитаем сколько покупателей в каждой когорте.

In [137…
```
cohort_sizes = orders_activity.groupby(['first_order_month']).agg({'uid':'nunique'}).reset_index()
```

In [138…
```
cohort_sizes.columns = ['first_order_month', 'n_buyers']
```

In [139…
```
cohort_sizes
```

Out[139…

	first_order_month	n_buyers
0	2017-06-01	2023
1	2017-07-01	1923
2	2017-08-01	1370
3	2017-09-01	2581
4	2017-10-01	4340
5	2017-11-01	4081
6	2017-12-01	4383
7	2018-01-01	3373
8	2018-02-01	3651
9	2018-03-01	3533
10	2018-04-01	2276
11	2018-05-01	2988
12	2018-06-01	1

Посчитаем выручку в каждый месяц для каждой когорты.

In [140…
```
cohorts_revenue = orders_activity.groupby(['first_order_month','cohort_lifetime']).agg({'revenue':'sum'}).reset_index()
```

In [141…
```
cohorts_revenue.head()
```

Out[141…

	first_order_month	cohort_lifetime	revenue

	first_order_month	cohort_lifetime	revenue
0	2017-06-01	0	9921.62
1	2017-06-01	1	835.17
2	2017-06-01	2	947.65
3	2017-06-01	3	2399.24
4	2017-06-01	4	1610.75

Объединим это с данными по количеству покупателей в период.

In [142…
```
report_revenue = cohort_sizes.merge(cohorts_revenue, on='first_order_month')
```

In [143…
```
report_revenue.head()
```

Out[143…

	first_order_month	n_buyers	cohort_lifetime	revenue
0	2017-06-01	2023	0	9921.62
1	2017-06-01	2023	1	835.17
2	2017-06-01	2023	2	947.65
3	2017-06-01	2023	3	2399.24
4	2017-06-01	2023	4	1610.75

Примем, что маржинальной равна 100% и вся выручка равняется прибыли компании.

In [144…
```
report_revenue['gp'] = report_revenue['revenue']
```

Посчитаем средний чек по периодам, разделив прибыль на количество продаж.

Расчитаем число покупок по когортам и период.

In [145…
```
orders_num = orders_activity.groupby(['first_order_month', 'cohort_lifetime']).agg({'uid':'count'}).reset_index()
```

In [146…
```
orders_num.columns = ['first_order_month', 'cohort_lifetime', 'n_orders']
```

In [147…
```
report_revenue = report_revenue.merge(orders_num, on=['first_order_month', 'cohort_lifetime'])
```

In [148…
```
report_revenue.head()
```

Out[148…

	first_order_month	n_buyers	cohort_lifetime	revenue	gp	n_orders
0	2017-06-01	2023	0	9921.62	9921.62	2414
1	2017-06-01	2023	1	835.17	835.17	157
2	2017-06-01	2023	2	947.65	947.65	167
3	2017-06-01	2023	3	2399.24	2399.24	275
4	2017-06-01	2023	4	1610.75	1610.75	265

Рассчитаем отношение количество заказов к количеству покупателей за период.

In [149…
```
cohort_orders_num = report_revenue.groupby('first_order_month')['n_orders'].sum().reset_index()
```

In [150…
```
cohort_orders_num.columns = ['first_order_month', 'cohort_n_orders']
```

In [151…
```
report_revenue = report_revenue.merge(cohort_orders_num, on='first_order_month')
```

In [152…
```
report_revenue['orders_per_buyer'] = report_revenue['cohort_n_orders'] / report_revenue['n_buyers']
```

In [153…
```
report_revenue[['first_order_month', 'orders_per_buyer']].plot(x='first_order_month', y='orders_per_buyer',
                                                               grid=True, figsize=(13,7), legend=False);
plt.title('Количество заказов на одного покупателя');
plt.xlabel('Месяц');
plt.ylabel('Количество заказов');
```

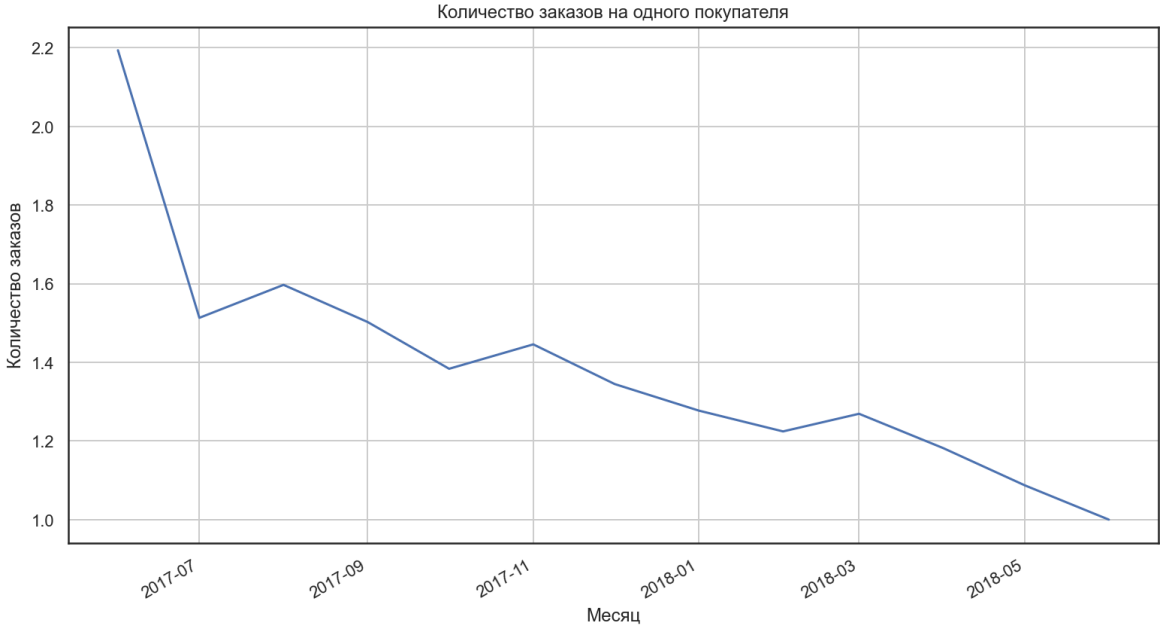

In [154…
```
report_revenue[['first_order_month', 'cohort_n_orders']].plot(x='first_order_month', y='cohort_n_orders',
                                                              grid=True, figsize=(13,7), legend=False);
plt.title('Общее количество заказов');
plt.xlabel('Месяц');
plt.ylabel('Количество заказов');
```

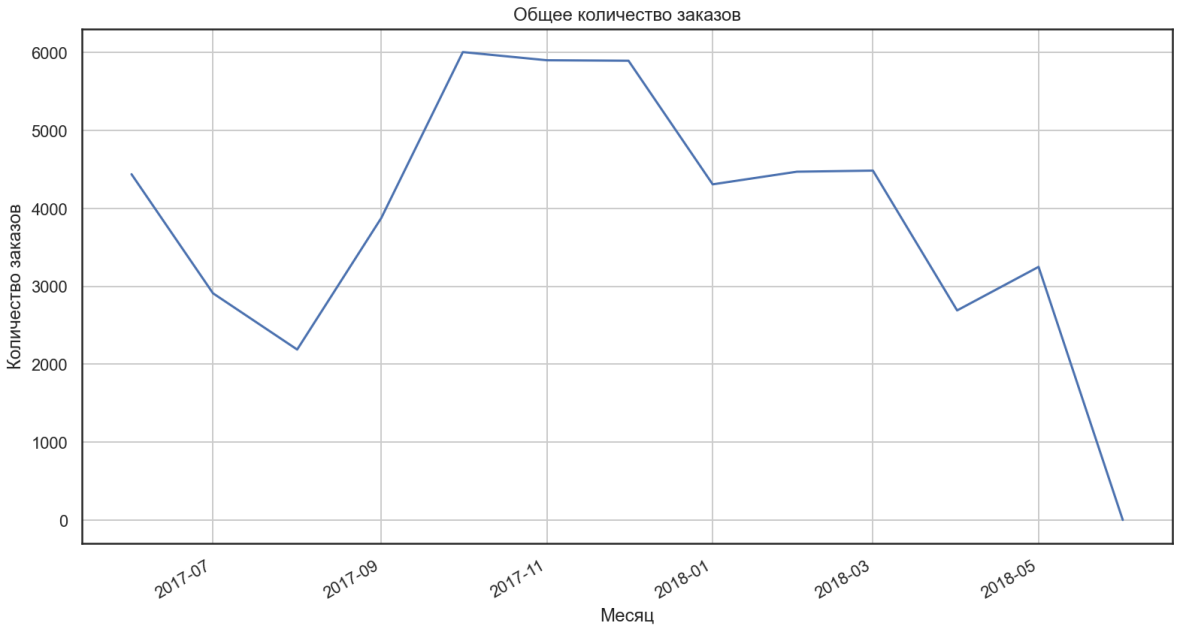

Как видно по графику выше количество заказов на одного покупателя падает, несмотря на то, что общее число заказов росло. Это может быть вызвано тем, что маркетинговые акции привлекали больше уникальных новых покупателей, но не возвращали старых. Таким образом, на текущий момент количество заказов практически равно количеству привлеченных новых пользователей.

In [155…
```
report_revenue['mean_bill'] = report_revenue['gp'] / report_revenue['n_orders']
```

In [156…
```
report_revenue
```

Out[156…

	first_order_month	n_buyers	cohort_lifetime	revenue	gp	n_orders	cohort_n_orders	orders_per_buyer	mean_bill
0	2017-06-01	2023	0	9921.62	9921.62	2414	4438	2.193772	4.110033
1	2017-06-01	2023	1	835.17	835.17	157	4438	2.193772	5.319554
2	2017-06-01	2023	2	947.65	947.65	167	4438	2.193772	5.674551
3	2017-06-01	2023	3	2399.24	2399.24	275	4438	2.193772	8.724509
4	2017-06-01	2023	4	1610.75	1610.75	265	4438	2.193772	6.078302
…	…	…	…	…	…	…	…	…	…

	first_order_month	n_buyers	cohort_lifetime	revenue	gp	n_orders	cohort_n_orders	orders_per_buyer	mean_bill
74	2018-03-01	3533	2	618.81	618.81	84	4484	1.269176	7.366786
75	2018-04-01	2276	0	11241.17	11241.17	2608	2690	1.181898	4.310265
76	2018-04-01	2276	1	569.44	569.44	82	2690	1.181898	6.944390
77	2018-05-01	2988	0	13925.76	13925.76	3249	3249	1.087349	4.286168
78	2018-06-01	1	0	3.42	3.42	1	1	1.000000	3.420000

79 rows × 9 columns

In [157…
```
mean_bill_pivot = report_revenue.pivot_table(
        index='first_order_month',
        columns='cohort_lifetime',
        values='mean_bill',
        aggfunc='mean').round(3)
```

In [158…
```
mean_bill_pivot
```

Out[158…

cohort_lifetime	0	1	2	3	4	...	7	8	9	10	11
first_order_month											
2017-06-01	4.110	5.320	5.675	8.725	6.078	...	7.016	5.262	9.567	11.200	5.907
2017-07-01	5.319	6.603	10.535	4.377	4.767	...	6.430	4.493	10.952	5.766	NaN
2017-08-01	4.772	6.074	7.364	7.135	7.186	...	9.535	5.599	8.445	NaN	NaN
2017-09-01	5.288	12.529	53.202	22.193	17.300	...	8.248	9.818	NaN	NaN	NaN
2017-10-01	4.489	6.495	5.101	5.776	4.852	...	3.475	NaN	NaN	NaN	NaN
2017-11-01	4.296	5.343	5.440	6.265	3.575	...	NaN	NaN	NaN	NaN	NaN
2017-12-01	4.108	7.383	20.907	28.700	27.903	...	NaN	NaN	NaN	NaN	NaN
2018-01-01	3.739	4.982	8.502	2.907	3.148	...	NaN	NaN	NaN	NaN	NaN
2018-02-01	3.744	3.848	3.747	3.867	NaN	...	NaN	NaN	NaN	NaN	NaN
2018-03-01	4.196	5.431	7.367	NaN	NaN	...	NaN	NaN	NaN	NaN	NaN
2018-04-01	4.310	6.944	NaN	NaN	NaN	...	NaN	NaN	NaN	NaN	NaN
2018-05-01	4.286	NaN	NaN	NaN	NaN	...	NaN	NaN	NaN	NaN	NaN
2018-06-01	3.420	NaN	NaN	NaN	NaN	...	NaN	NaN	NaN	NaN	NaN

13 rows × 12 columns

In [159…
```
sns.set(style='white');
plt.figure(figsize=(13, 9));
plt.title('Средний чек по когортам');
sns.heatmap(mean_bill_pivot, annot=True, fmt='.1f', linewidths=1, linecolor='gray');
plt.xlabel('Время жизни когорты');
plt.ylabel('Когорта');
```

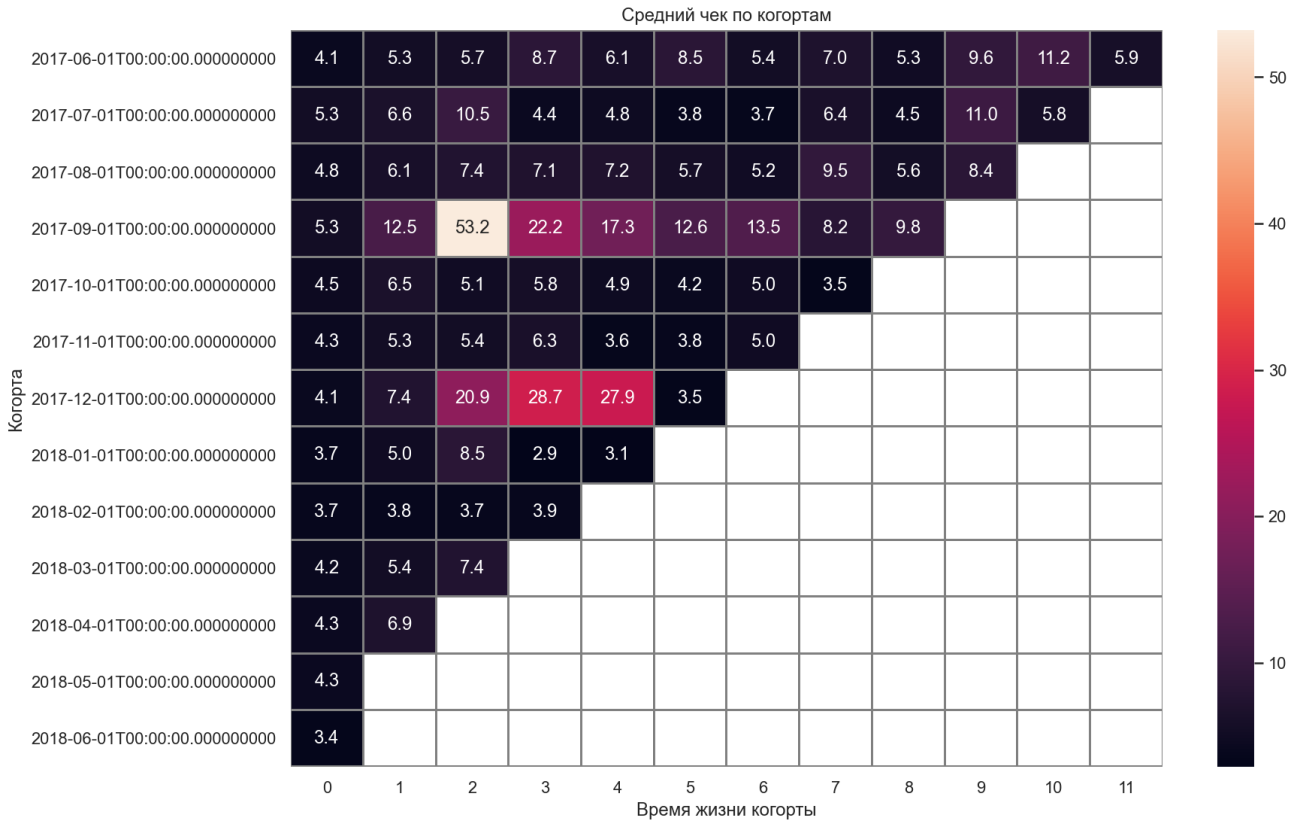

Наибольший средний чек в размере 53.2 наблюдался для когорты сентября 2017 года в ноябре на третий месяц жизни когорты. Также для когорты клиентов, которые впервые делали заказ в декабре 2017 года, видно, что максимальный средний чек для них был в феврале, марте и апреле 2018 года, что, возможно, связано с праздниками в это время.

Расчитаем LTV Lifetime Value для клиента. Для этого валовую прибыль нужно разделить на количество покупателей.

In [160…
```
report_revenue['ltv'] = report_revenue['gp'] / report_revenue['n_buyers']
```

In [161…
```
report_revenue
```

Out[161…

	first_order_month	n_buyers	cohort_lifetime	revenue	gp	n_orders	cohort_n_orders	orders_per_buyer	mean_bill	ltv
0	2017-06-01	2023	0	9921.62	9921.62	2414	4438	2.193772	4.110033	4.904409
1	2017-06-01	2023	1	835.17	835.17	157	4438	2.193772	5.319554	0.412837
2	2017-06-01	2023	2	947.65	947.65	167	4438	2.193772	5.674551	0.468438
3	2017-06-01	2023	3	2399.24	2399.24	275	4438	2.193772	8.724509	1.185981
4	2017-06-01	2023	4	1610.75	1610.75	265	4438	2.193772	6.078302	0.796218
...	...	...	...	...	...	...	...	...	...	...
74	2018-03-01	3533	2	618.81	618.81	84	4484	1.269176	7.366786	0.175151
75	2018-04-01	2276	0	11241.17	11241.17	2608	2690	1.181898	4.310265	4.939003
76	2018-04-01	2276	1	569.44	569.44	82	2690	1.181898	6.944390	0.250193
77	2018-05-01	2988	0	13925.76	13925.76	3249	3249	1.087349	4.286168	4.660562
78	2018-06-01	1	0	3.42	3.42	1	1	1.000000	3.420000	3.420000

79 rows × 10 columns

In [162…
```
report_revenue.groupby('first_order_month')['n_orders'].sum()
```

Out[162…
```
first_order_month
2017-06-01    4438
2017-07-01    2910
2017-08-01    2188
2017-09-01    3878
2017-10-01    6005
2017-11-01    5900
2017-12-01    5894
2018-01-01    4308
2018-02-01    4470
2018-03-01    4484
```

```
2018-04-01    2690
2018-05-01    3249
2018-06-01       1
Name: n_orders, dtype: int64
```

In [163…
```
ltv_pivot = report_revenue.pivot_table(
        index='first_order_month',
        columns='cohort_lifetime',
        values='ltv',
        aggfunc='mean').round(2)
```

In [164…
```
ltv_pivot
```

Out[164…

cohort_lifetime	0	1	2	3	4	…	7	8	9	10	11
first_order_month											
2017-06-01	4.90	0.41	0.47	1.19	0.80	…	0.64	0.56	0.57	0.50	0.2
2017-07-01	6.20	0.31	0.68	0.18	0.17	…	0.19	0.09	0.17	0.12	NaN
2017-08-01	5.60	0.44	0.48	0.41	0.36	…	0.42	0.17	0.08	NaN	NaN
2017-09-01	6.30	0.77	3.67	0.78	0.66	…	0.14	0.16	NaN	NaN	NaN
2017-10-01	5.32	0.31	0.17	0.18	0.12	…	0.07	NaN	NaN	NaN	NaN
2017-11-01	5.38	0.27	0.27	0.28	0.06	…	NaN	NaN	NaN	NaN	NaN
2017-12-01	4.86	0.40	0.95	0.82	0.57	…	NaN	NaN	NaN	NaN	NaN
2018-01-01	4.37	0.25	0.22	0.07	0.03	…	NaN	NaN	NaN	NaN	NaN
2018-02-01	4.34	0.13	0.08	0.04	NaN	…	NaN	NaN	NaN	NaN	NaN
2018-03-01	5.04	0.24	0.18	NaN	NaN	…	NaN	NaN	NaN	NaN	NaN
2018-04-01	4.94	0.25	NaN	NaN	NaN	…	NaN	NaN	NaN	NaN	NaN
2018-05-01	4.66	NaN	NaN	NaN	NaN	…	NaN	NaN	NaN	NaN	NaN
2018-06-01	3.42	NaN	NaN	NaN	NaN	…	NaN	NaN	NaN	NaN	NaN

13 rows × 12 columns

Для лучшей визуализации посчитаем накопительную сумму LTV по времени жизни когорт.

In [165…
```
ltv_report = ltv_pivot.cumsum(axis=1).round(2)
```

In [166…
```
plt.figure(figsize=(13, 9));
plt.title('Накопительная сумма LTV по периодам для каждой когорты');
sns.heatmap(ltv_report, annot=True, fmt='.2f', linewidths=1, linecolor='gray');
plt.xlabel('Время жизни когорты');
plt.ylabel('Когорта');
```

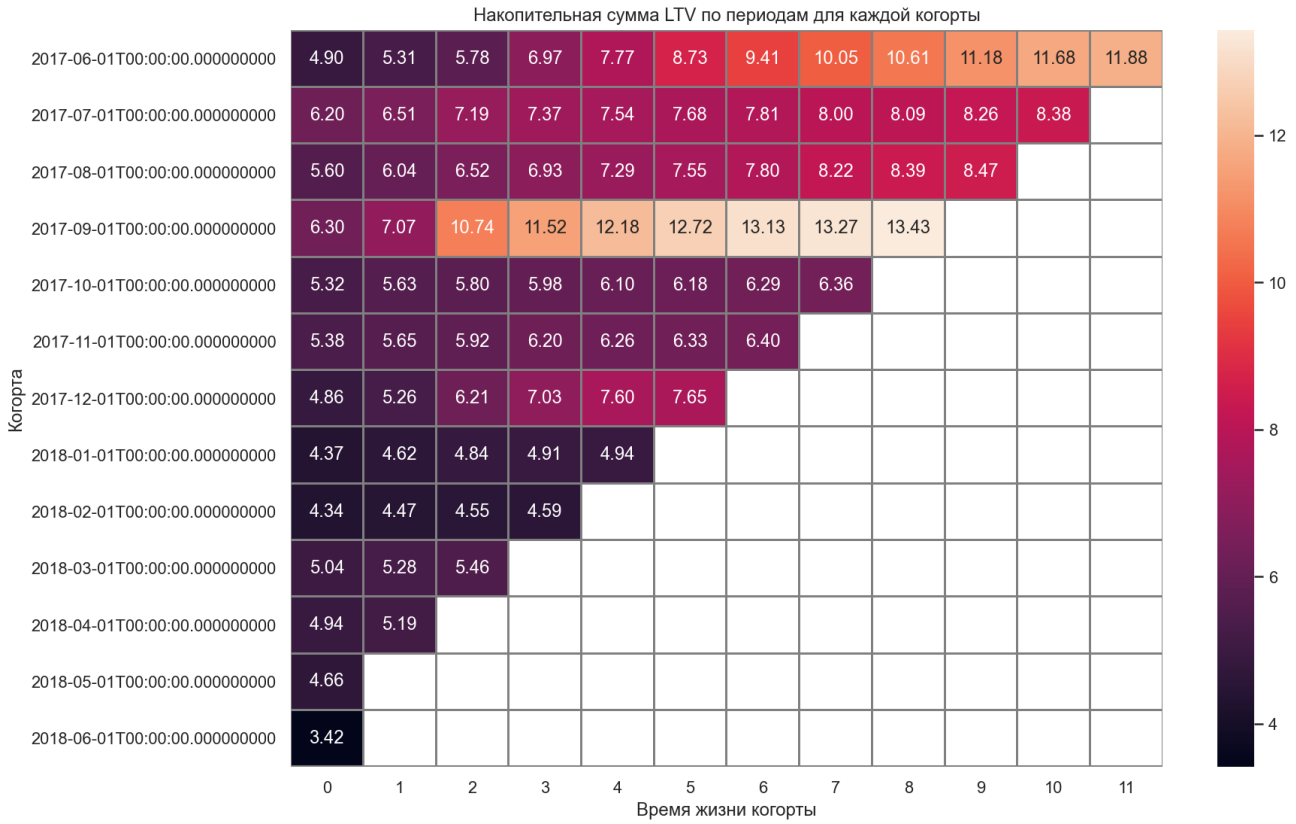

Как видно на визуализации с накопительным LTV когорта сентября 2017 уже на второй месяц принесла больше дохода, чем когорта июня 2017 после 4 месяцев, а на третий месяц принесла больше, чем на 7 месяц первый когорты. На втором месте по скорости принесения прибыли когорта июля 2017 года, которая уже на втором периоде принесла больше, чем за 3 периода когорта июня 2017 года.

Как видно по графику, наибольшую прибыль принесла когорта пользователей сентября 2017 года (LTV = 13.4), далее идет первая когорта (которая также может включать все предыдущие периоды) (LTV = 11.9). С течением времени LTV уменьшается.

Если сравнить отдельно когорты, которые прожили как минимум 6 периодов, то среди них также лучшей окажется когорта сентября, затем когорта июня, июля и августа. Когорты октября и ноября показали практически в 2 раза меньший результат, чем когорта сентября за тот же срок.

Анализ затрат на маркетинг

- Сколько денег потратили? Всего / на каждый источник / по времени
- Сколько стоило привлечение одного покупателя из каждого источника?
- На сколько окупились расходы? (ROI)

Проанализируем таблицу с расходами.

In [167…
```
costs.head()
```

Out[167…

	source_id	dt	costs
0	1	2017-06-01	75.20
1	1	2017-06-02	62.25
2	1	2017-06-03	36.53
3	1	2017-06-04	55.00
4	1	2017-06-05	57.08

Посчитаем общие затраты.

In [168…
```
costs['costs'].sum()
```

Out[168… `329131.62`

Всего затрат за год на 329131.62.

Рассчитаем траты в месяц по разным источникам.

In [169…
```
costs['month'] = costs['dt'].astype('datetime64[M]')
```

In [170…
```
costs_monthly = costs.groupby(['source_id', 'month'])['costs'].sum().reset_index()
```

In [171…
```
costs_monthly.head()
```

Out[171…

	source_id	month	costs
0	1	2017-06-01	1125.61
1	1	2017-07-01	1072.88
2	1	2017-08-01	951.81
3	1	2017-09-01	1502.01
4	1	2017-10-01	2315.75

In [172…
```
costs.groupby('source_id')['costs'].sum().reset_index()
```

Out[172…

	source_id	costs
0	1	20833.27
1	2	42806.04
2	3	141321.63
3	4	61073.60
4	5	51757.10
5	9	5517.49
6	10	5822.49

In [173…
```
costs.groupby('source_id')['costs'].sum().reset_index().plot(kind='pie', y='costs',
                                    autopct='%1.1f%%', labels=costs['source_id'].unique(),
                                                          figsize=(13,6));
plt.title('Доли расходов на разные типы источников');
```

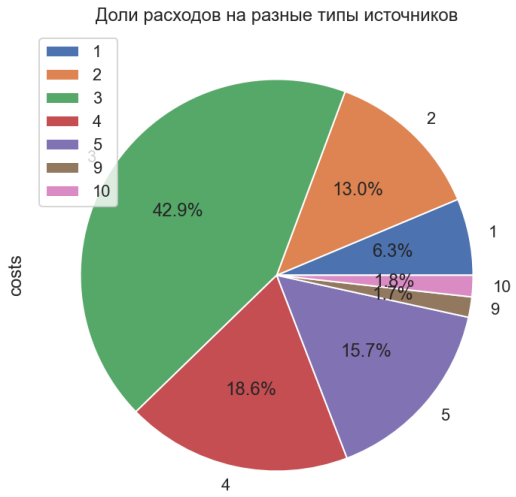

In [174…
```
costs.groupby('month')['costs'].sum().reset_index()
```

Out[174…

	month	costs
0	2017-06-01	18015.00
1	2017-07-01	18240.59
2	2017-08-01	14790.54
3	2017-09-01	24368.91
4	2017-10-01	36322.88
5	2017-11-01	37907.88
6	2017-12-01	38315.35
7	2018-01-01	33518.52
8	2018-02-01	32723.03

	month	costs
9	2018-03-01	30415.27
10	2018-04-01	22289.38
11	2018-05-01	22224.27

In [175…
```
plt.figure(figsize=(13,7));
for label, grp in costs_monthly.groupby('source_id'):
    grp.plot(x='month', y='costs', ax=plt.gca(), label=label, grid=True)
plt.title('График затрат по времени для разных источников');
plt.legend(title="Источник");
plt.xlabel('Месяц');
plt.ylabel('Сумма затрат');
```

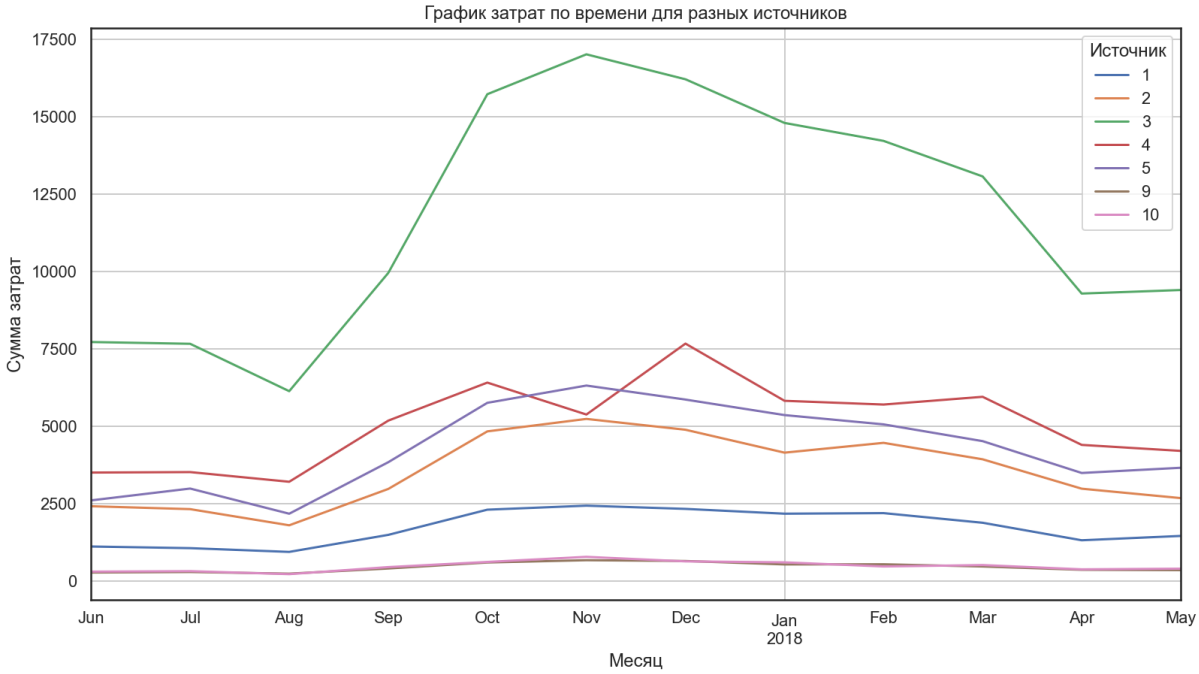

Больше всего затрат было потрачено на источник 3 в размере 141321.63. Затраты по времени были максимальны в ноябре 2017 года и минимальны в августе 2017 года. Судя по графику выше расходы нарастали с сентября 2017 года и убывали, начиная с декабря 2017 года вплоть до конца выборки.

Рассчитаем расходы на привлечение одного клиента. Для этого совместим подготовленный датафрейм с количеством покупателей в каждой когорте

In [176…
```
costs_monthly = cohort_sizes.merge(costs_monthly, left_on='first_order_month', right_on='month')
```

In [177…
```
costs_monthly
```

Out[177…

	first_order_month	n_buyers	source_id	month	costs
0	2017-06-01	2023	1	2017-06-01	1125.61
1	2017-06-01	2023	2	2017-06-01	2427.38
2	2017-06-01	2023	3	2017-06-01	7731.65
3	2017-06-01	2023	4	2017-06-01	3514.80
4	2017-06-01	2023	5	2017-06-01	2616.12
...	...	...	...	...	...
79	2018-05-01	2988	3	2018-05-01	9411.42
80	2018-05-01	2988	4	2018-05-01	4214.21
81	2018-05-01	2988	5	2018-05-01	3669.56
82	2018-05-01	2988	9	2018-05-01	362.17
83	2018-05-01	2988	10	2018-05-01	409.86

84 rows × 5 columns

In [178…
```
costs_monthly.groupby('month')['n_buyers'].sum()
```

Out[178…
```
month
2017-06-01    14161
2017-07-01    13461
2017-08-01     9590
2017-09-01    18067
2017-10-01    30380
2017-11-01    28567
2017-12-01    30681
2018-01-01    23611
2018-02-01    25557
2018-03-01    24731
2018-04-01    15932
2018-05-01    20916
Name: n_buyers, dtype: int64
```

Определим откуда пришли пользователи-посетители в первый раз.

In [179…
```
visits_sources = visits_log.sort_values(by = ['uid', 'start_ts']).groupby('uid').agg({'source_id': 'first'})
```

In [180…
```
visits_sources
```

Out[180…

uid	source_id
11863502262781	3
49537067089222	2
297729379853735	3
313578113262317	2
325320750514679	5
…	…
18446403737806311543	5
18446424184725333426	4
18446556406699109058	3
18446621818809592527	4
18446676030785672386	3

228169 rows × 1 columns

Соединим первые покупки и источники.

In [181…
```
buyers_first_time = orders_log.groupby('uid').agg({'buy_ts': 'min'})
```

In [182…
```
buyers_first_time
```

Out[182…

uid	buy_ts
313578113262317	2018-01-03 21:51:00
1575281904278712	2017-06-03 10:13:00
2429014661409475	2017-10-11 18:33:00
2464366381792757	2018-01-28 15:54:00
2551852515556206	2017-11-24 10:14:00
…	…
18445147675727495770	2017-11-24 09:03:00
18445407535914413204	2017-09-22 23:55:00
18445601152732270159	2018-03-26 22:54:00
18446156210226471712	2018-02-18 19:34:00
18446167067214817906	2017-10-17 10:16:00

36523 rows × 1 columns

In [183…
```
buyers_first_time = buyers_first_time.merge(visits_sources, on='uid')
```

In [184…
```
buyers_first_time
```

Out[184…

uid	buy_ts	source_id
313578113262317	2018-01-03 21:51:00	2
1575281904278712	2017-06-03 10:13:00	10
2429014661409475	2017-10-11 18:33:00	3
2464366381792757	2018-01-28 15:54:00	5
2551852515556206	2017-11-24 10:14:00	5
...	...	...
18445147675727495770	2017-11-24 09:03:00	5
18445407535914413204	2017-09-22 23:55:00	3
18445601152732270159	2018-03-26 22:54:00	2
18446156210226471712	2018-02-18 19:34:00	3
18446167067214817906	2017-10-17 10:16:00	5

36523 rows × 2 columns

In [185…
```
buyers_first_time = buyers_first_time.rename(columns = {'buy_ts': 'first_order'})
```

In [186…
```
buyers_first_time
```

Out[186…

uid	first_order	source_id
313578113262317	2018-01-03 21:51:00	2
1575281904278712	2017-06-03 10:13:00	10
2429014661409475	2017-10-11 18:33:00	3
2464366381792757	2018-01-28 15:54:00	5
2551852515556206	2017-11-24 10:14:00	5
...	...	...
18445147675727495770	2017-11-24 09:03:00	5
18445407535914413204	2017-09-22 23:55:00	3
18445601152732270159	2018-03-26 22:54:00	2
18446156210226471712	2018-02-18 19:34:00	3
18446167067214817906	2017-10-17 10:16:00	5

36523 rows × 2 columns

Получили таблицу с распределением первых заказов по источникам для каждого клиента.

Для расчета LTV добавим заказы к таблице с первыми заказами.

In [187…
```
ltv_table = buyers_first_time.merge(orders_log, on='uid')
```

In [188…
```
ltv_table.head()
```

Out[188…

	uid	first_order	source_id	buy_ts	revenue
0	313578113262317	2018-01-03 21:51:00	2	2018-01-03 21:51:00	0.55
1	1575281904278712	2017-06-03 10:13:00	10	2017-06-03 10:13:00	1.22
2	1575281904278712	2017-06-03 10:13:00	10	2017-06-03 17:39:00	1.83
3	2429014661409475	2017-10-11 18:33:00	3	2017-10-11 18:33:00	73.33
4	2464366381792757	2018-01-28 15:54:00	5	2018-01-28 15:54:00	2.44

Расчитаем время жизни когорты.

In [189…
```
ltv_table['cohort_lifetime'] = ((ltv_table['buy_ts'] - ltv_table['first_order']) \
                                / np.timedelta64(1,'M')).round().astype(int)
```

In [190…
```
ltv_table
```

Out[190…

	uid	first_order	source_id	buy_ts	revenue	cohort_lifetime
0	313578113262317	2018-01-03 21:51:00	2	2018-01-03 21:51:00	0.55	0
1	1575281904278712	2017-06-03 10:13:00	10	2017-06-03 10:13:00	1.22	0
2	1575281904278712	2017-06-03 10:13:00	10	2017-06-03 17:39:00	1.83	0
3	2429014661409475	2017-10-11 18:33:00	3	2017-10-11 18:33:00	73.33	0
4	2464366381792757	2018-01-28 15:54:00	5	2018-01-28 15:54:00	2.44	0
...	...	...	...	...	...	...
50410	18445407535914413204	2017-09-22 23:55:00	3	2017-09-24 23:48:00	0.24	0
50411	18445407535914413204	2017-09-22 23:55:00	3	2017-09-25 15:56:00	0.12	0
50412	18445601152732270159	2018-03-26 22:54:00	2	2018-03-26 22:54:00	4.22	0
50413	18446156210226471712	2018-02-18 19:34:00	3	2018-02-18 19:34:00	9.78	0
50414	18446167067214817906	2017-10-17 10:16:00	5	2017-10-17 10:16:00	7.94	0

50415 rows × 6 columns

Для расчета количества заказов по источникам составим сводную таблицу.

In [191…
```
orders_lifetime = ltv_table.pivot_table(index='source_id',
                                        columns='cohort_lifetime',
                                        values='revenue',
                                        aggfunc='count').fillna(0)
```

In [192…
```
orders_lifetime
```

Out[192…

cohort_lifetime	0	1	2	3	4	...	8	9	10	11	12
source_id											
1	3498.0	284.0	247.0	242.0	189.0	...	109.0	86.0	62.0	34.0	10.0
2	4380.0	621.0	398.0	283.0	177.0	...	100.0	41.0	40.0	16.0	7.0
3	11708.0	493.0	331.0	214.0	157.0	...	48.0	16.0	15.0	8.0	11.0
4	11550.0	341.0	236.0	188.0	167.0	...	46.0	30.0	18.0	8.0	6.0
5	7956.0	283.0	245.0	196.0	153.0	...	80.0	60.0	16.0	9.0	2.0
7	1.0	0.0	0.0	0.0	0.0	...	0.0	0.0	0.0	0.0	0.0
9	1272.0	81.0	59.0	69.0	46.0	...	19.0	9.0	3.0	0.0	0.0
10	1469.0	29.0	13.0	23.0	7.0	...	4.0	2.0	0.0	0.0	0.0

8 rows × 13 columns

In [193…
```
plt.figure(figsize=(15, 6));
plt.title('Количество заказов по разным источникам и периодам');
sns.heatmap(orders_lifetime, annot=True, fmt='.0f', linewidths=1, linecolor='gray');
plt.xlabel('Время жизни когорты');
plt.ylabel('Источник');
```

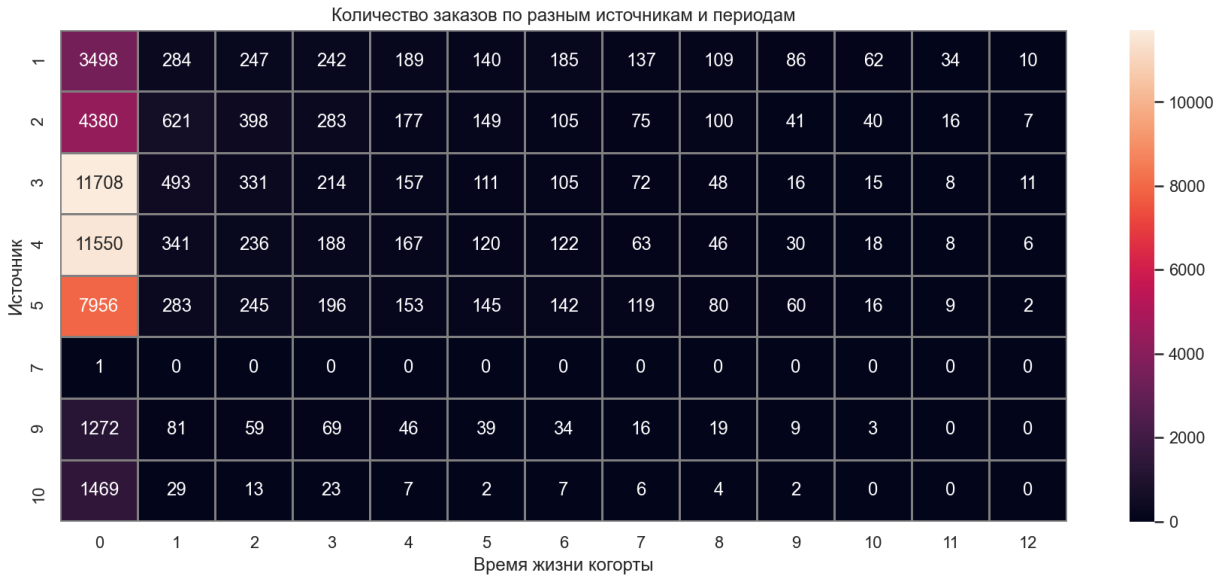

Больше всего заказов было размещено после источника трафика 3, затем 4 и 5. Продаж через источники 6,7,8 практически не было. На второй месяц продажи уменьшались практически на порядок для всех источников.

Теперь рассчитаем количество покупателей по источникам и времени жизни когорты.

In [194…
```
buyers_lifetime = ltv_table.pivot_table(index='source_id',
                                        columns='cohort_lifetime',
                                        values='uid',
                                        aggfunc='nunique').fillna(0)
```

In [195…
```
buyers_lifetime
```

Out[195…

cohort_lifetime	0	1	2	3	4	…	8	9	10	11	12
source_id											
1	2899.0	110.0	92.0	59.0	57.0	…	23.0	14.0	15.0	10.0	6.0
2	3506.0	159.0	132.0	99.0	88.0	…	29.0	17.0	18.0	9.0	5.0
3	10473.0	286.0	227.0	149.0	111.0	…	45.0	14.0	15.0	8.0	8.0
4	10296.0	272.0	189.0	153.0	110.0	…	37.0	23.0	12.0	7.0	5.0
5	6931.0	175.0	124.0	79.0	79.0	…	25.0	19.0	7.0	6.0	2.0
7	1.0	0.0	0.0	0.0	0.0	…	0.0	0.0	0.0	0.0	0.0
9	1088.0	68.0	52.0	45.0	37.0	…	13.0	8.0	3.0	0.0	0.0
10	1329.0	26.0	12.0	19.0	6.0	…	4.0	1.0	0.0	0.0	0.0

8 rows × 13 columns

In [196…
```
plt.figure(figsize=(15, 6));
plt.title('Количество клиентов с заказами по разным источникам и периодам');
sns.heatmap(buyers_lifetime, annot=True, fmt='.0f', linewidths=1, linecolor='gray');
plt.xlabel('Время жизни когорты');
plt.ylabel('Источник');
```

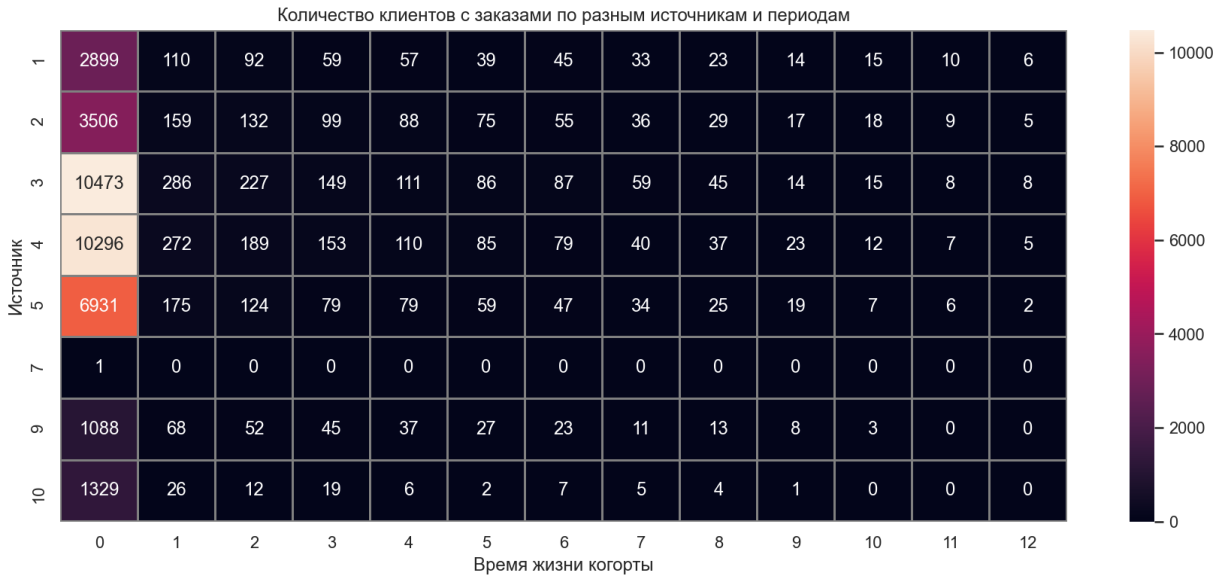

Видно, что количество клиентов с заказами повторяет распределение количества заказов по источникам.

Для расчета LTV сначала расчитаем доход по источникам и времени жизни когорт.

In [197…
```
ltv_results = ltv_table.pivot_table(index='source_id',
                                    columns='cohort_lifetime',
                                    values='revenue',
                                    aggfunc='sum').fillna(0)
```

In [198…
```
ltv_results
```

Out[198…

cohort_lifetime	0	1	2	3	4	…	8	9	10	11	12
source_id											
1	17846.78	2883.49	2146.19	1874.49	1425.00	…	940.43	752.60	309.32	336.13	148.05
2	23737.70	4502.22	5831.11	5384.22	2266.59	…	781.76	218.08	397.70	117.20	11.85
3	46894.89	2634.89	1429.20	1491.36	784.89	…	195.68	53.66	54.69	11.88	11.49
4	47204.71	1579.06	1175.28	991.91	1232.90	…	198.87	390.26	559.93	28.34	13.44
5	34030.40	1416.06	2465.93	9473.11	1635.71	…	416.77	423.77	44.88	66.24	1.77
7	1.22	0.00	0.00	0.00	0.00	…	0.00	0.00	0.00	0.00	0.00
9	4222.42	311.70	261.81	294.70	118.92	…	128.19	44.11	9.35	0.00	0.00
10	4205.13	84.13	36.23	63.61	18.63	…	3.66	3.36	0.00	0.00	0.00

8 rows × 13 columns

Для получения LTV нужно получить кумулятивную сумму по строкам.

In [199…
```
ltv_results = ltv_results.cumsum(axis=1)
```

In [200…
```
ltv_results
```

Out[200…

cohort_lifetime	0	1	2	3	4	…	8	9	10	11	12
source_id											
1	17846.78	20730.27	22876.46	24750.95	26175.95	…	29544.45	30297.05	30606.37	30942.50	31090.55
2	23737.70	28239.92	34071.03	39455.25	41721.84	…	46178.78	46396.86	46794.56	46911.76	46923.61
3	46894.89	49529.78	50958.98	52450.34	53235.23	…	54379.52	54433.18	54487.87	54499.75	54511.24
4	47204.71	48783.77	49959.05	50950.96	52183.86	…	55704.86	56095.12	56655.05	56683.39	56696.83
5	34030.40	35446.46	37912.39	47385.50	49021.21	…	52087.36	52511.13	52556.01	52622.25	52624.02
7	1.22	1.22	1.22	1.22	1.22	…	1.22	1.22	1.22	1.22	1.22
9	4222.42	4534.12	4795.93	5090.63	5209.55	…	5705.94	5750.05	5759.40	5759.40	5759.40
10	4205.13	4289.26	4325.49	4389.10	4407.73	…	4446.97	4450.33	4450.33	4450.33	4450.33

8 rows × 13 columns

In [201…
```
plt.figure(figsize=(15, 6));
plt.title('Накапливаемая сумма выручки по разным источникам и периодам');
sns.heatmap(ltv_results, annot=True, fmt='.0f', linewidths=1, linecolor='gray');
plt.xlabel('Время жизни когорты');
plt.ylabel('Источник');
```

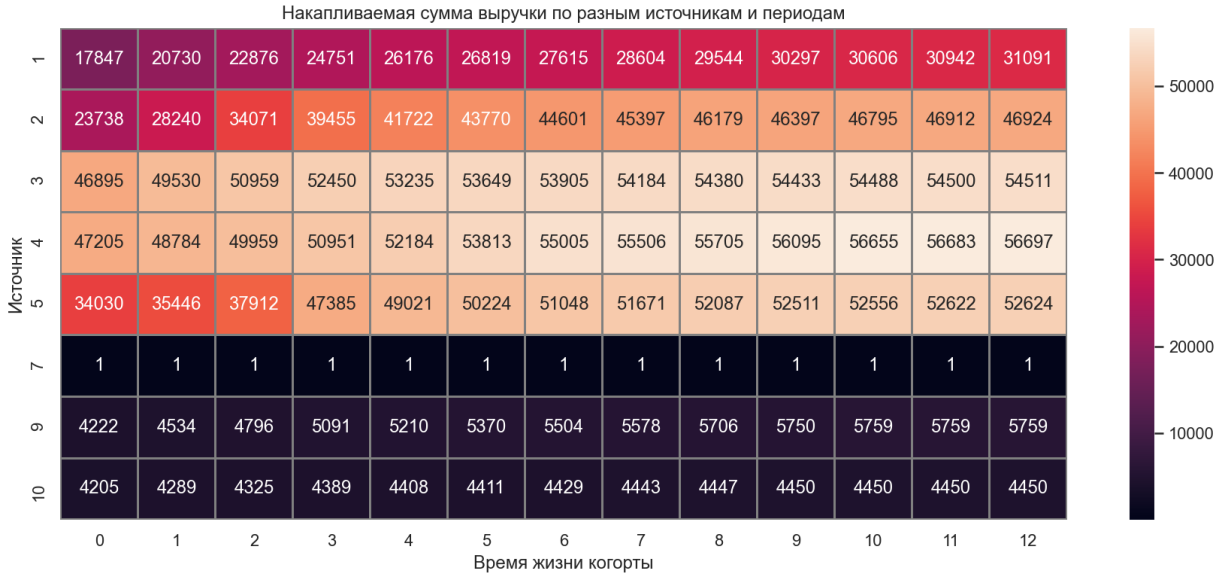

Как видно по тепловой карте больше всего выручки принес источник 4, затем 3, 5. Источники 9 и 10 сильно отстают от других источников по прибыли. Видно, что между 2 и 3 периодом (август-сентябрь 2017) произошло резкое увеличение выручки по источнику 5 (на 10 тыс.). Это, по-видимому, связано с увеличением бюджета на этот источник и привлечением новых пользователей через этот канал.

Далее для расчета LTV получим количество покупателей в каждый период по источникам.

In [202…
```
cohort_buyers = buyers_first_time.reset_index().groupby('source_id').agg({'uid':'nunique'})
```

In [203…
```
cohort_buyers
```

Out[203…

source_id	uid
1	2899
2	3506
3	10473
4	10296
5	6931
7	1
9	1088
10	1329

In [204…
```
cohort_buyers = cohort_buyers.rename(columns = {'uid':'cohort_size'})
```

Получившееся количество покупателей добавим к таблице для расчета LTV.

In [205…
```
ltv_output = ltv_results.merge(cohort_buyers, on = 'source_id')
```

In [206…
```
ltv_output
```

Out[206…

source_id	0	1	2	3	4	…	9	10	11	12	cohort_size
1	17846.78	20730.27	22876.46	24750.95	26175.95	…	30297.05	30606.37	30942.50	31090.55	2899
2	23737.70	28239.92	34071.03	39455.25	41721.84	…	46396.86	46794.56	46911.76	46923.61	3506
3	46894.89	49529.78	50958.98	52450.34	53235.23	…	54433.18	54487.87	54499.75	54511.24	10473
4	47204.71	48783.77	49959.05	50950.96	52183.86	…	56095.12	56655.05	56683.39	56696.83	10296

source_id	0	1	2	3	4	...	9	10	11	12	cohort_size
5	34030.40	35446.46	37912.39	47385.50	49021.21	...	52511.13	52556.01	52622.25	52624.02	6931
7	1.22	1.22	1.22	1.22	1.22	...	1.22	1.22	1.22	1.22	1
9	4222.42	4534.12	4795.93	5090.63	5209.55	...	5750.05	5759.40	5759.40	5759.40	1088
10	4205.13	4289.26	4325.49	4389.10	4407.73	...	4450.33	4450.33	4450.33	4450.33	1329

8 rows × 14 columns

Теперь можно разделить кумулятивную сумму на количество покупателей по-элементно.

In [207…
```
ltv_output = ltv_output.div(ltv_output['cohort_size'], axis=0)
```

In [208…
```
# Столбец с размерами больше не нужен.
ltv_output = ltv_output.drop(columns = 'cohort_size')
```

In [209…
```
ltv_output
```

Out[209…

source_id	0	1	2	3	4	...	8	9	10	11	12
1	6.156185	7.150835	7.891156	8.537754	9.029303	...	10.191256	10.450862	10.557561	10.673508	10.724577
2	6.770593	8.054740	9.717921	11.253637	11.900125	...	13.171358	13.233560	13.346994	13.380422	13.383802
3	4.477694	4.729283	4.865748	5.008149	5.083093	...	5.192354	5.197477	5.202699	5.203834	5.204931
4	4.584762	4.738128	4.852278	4.948617	5.068362	...	5.410340	5.448244	5.502627	5.505380	5.506685
5	4.909883	5.114191	5.469974	6.836748	7.072747	...	7.515129	7.576270	7.582746	7.592303	7.592558
7	1.220000	1.220000	1.220000	1.220000	1.220000	...	1.220000	1.220000	1.220000	1.220000	1.220000
9	3.880901	4.167390	4.408024	4.678888	4.788189	...	5.244430	5.284972	5.293566	5.293566	5.293566
10	3.164131	3.227434	3.254695	3.302558	3.316576	...	3.346102	3.348631	3.348631	3.348631	3.348631

8 rows × 13 columns

In [210…
```
plt.figure(figsize=(15, 6));
plt.title('Накопительный LTV по разным источникам и периодам');
sns.heatmap(ltv_output, annot=True, fmt='.2f', linewidths=1, linecolor='gray');
plt.xlabel('Время жизни когорты');
plt.ylabel('Источник');
```

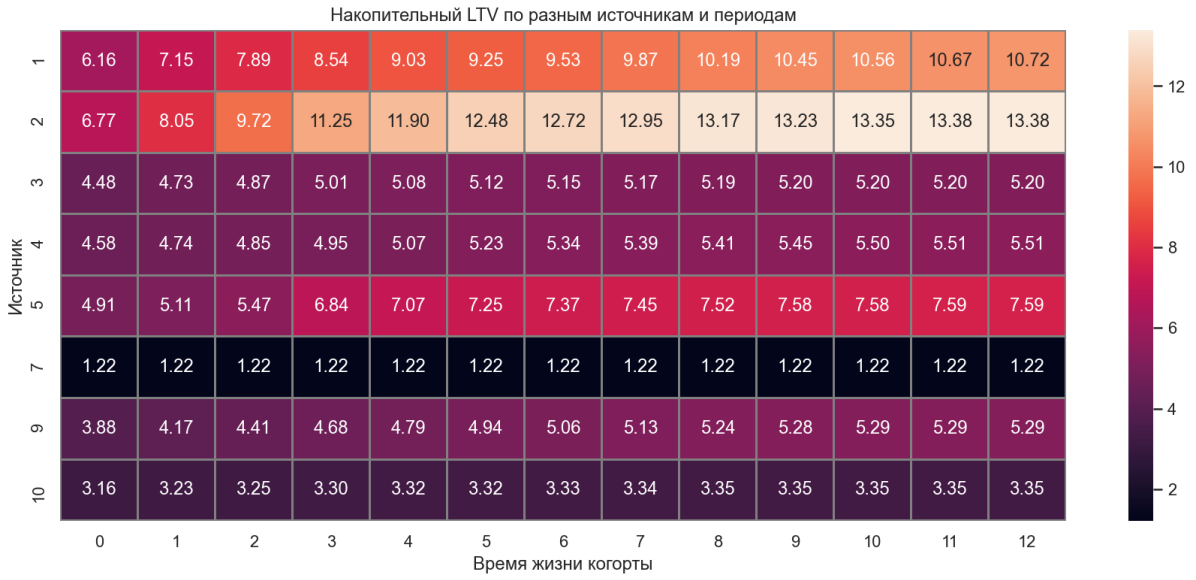

По распределению видно, что наибольший LTV у источника 2, затем 1 и 5 на конец выборки. В то же время, скорость изменения LTV различна по каналам. Так, например, источники 1 и 2 быстрее других наращивали LTV, а на 3 период (сентябрь 2017) источник 5 резко увеличил LTV.

Посчитаем CAC из таблицы с затратами по источникам.

In [211…
```
cac_table = costs.groupby('source_id').agg({'costs': 'sum'})
```

In [212…
```
cac_table
```

Out[212…

source_id	costs
1	20833.27
2	42806.04
3	141321.63
4	61073.60
5	51757.10
9	5517.49
10	5822.49

Совместим эту таблицу с количеством покупателей по источникам.

In [213…
```
cac_table = cac_table.reset_index().merge(cohort_buyers.reset_index(), on='source_id')
```

In [214…
```
cac_table
```

Out[214…

	source_id	costs	cohort_size
0	1	20833.27	2899
1	2	42806.04	3506
2	3	141321.63	10473
3	4	61073.60	10296
4	5	51757.10	6931
5	9	5517.49	1088
6	10	5822.49	1329

In [215…
```
cac_table['cac'] = cac_table['costs'] / cac_table['cohort_size']
```

In [216…
```
cac_table
```

Out[216…

	source_id	costs	cohort_size	cac
0	1	20833.27	2899	7.186364
1	2	42806.04	3506	12.209367
2	3	141321.63	10473	13.493901
3	4	61073.60	10296	5.931779
4	5	51757.10	6931	7.467479
5	9	5517.49	1088	5.071222
6	10	5822.49	1329	4.381106

Сделаем индексом `source_id` по примеру других таблиц.

In [217…
```
cac_table = cac_table.set_index('source_id')
```

In [218…
```
cac_table
```

Out[218…

source_id	costs	cohort_size	cac
1	20833.27	2899	7.186364
2	42806.04	3506	12.209367
3	141321.63	10473	13.493901
4	61073.60	10296	5.931779
5	51757.10	6931	7.467479
9	5517.49	1088	5.071222

source_id	costs	cohort_size	cac
10	5822.49	1329	4.381106

Наконец все готово для расчета ROMI.

In [219…
```
romi_table = ltv_output.merge(cac_table[['cac']], on='source_id')
```

In [220…
```
romi_table
```

Out[220…

source_id	0	1	2	3	4	…	9	10	11	12	cac
1	6.156185	7.150835	7.891156	8.537754	9.029303	…	10.450862	10.557561	10.673508	10.724577	7.186364
2	6.770593	8.054740	9.717921	11.253637	11.900125	…	13.233560	13.346994	13.380422	13.383802	12.209367
3	4.477694	4.729283	4.865748	5.008149	5.083093	…	5.197477	5.202699	5.203834	5.204931	13.493901
4	4.584762	4.738128	4.852278	4.948617	5.068362	…	5.448244	5.502627	5.505380	5.506685	5.931779
5	4.909883	5.114191	5.469974	6.836748	7.072747	…	7.576270	7.582746	7.592303	7.592558	7.467479
9	3.880901	4.167390	4.408024	4.678888	4.788189	…	5.284972	5.293566	5.293566	5.293566	5.071222
10	3.164131	3.227434	3.254695	3.302558	3.316576	…	3.348631	3.348631	3.348631	3.348631	4.381106

7 rows × 14 columns

Теперь разделим таблицу с LTV на CAC, чтобы получить ROMI. Последний столбец также удалим.

In [221…
```
romi_table = romi_table.div(romi_table['cac'], axis=0).drop(columns='cac')
```

In [222…
```
romi_table
```

Out[222…

source_id	0	1	2	3	4	…	8	9	10	11	12
1	0.856648	0.995056	1.098073	1.188049	1.256449	…	1.418138	1.454263	1.469110	1.485245	1.492351
2	0.554541	0.659718	0.795940	0.921722	0.974672	…	1.078791	1.083886	1.093177	1.095915	1.096191
3	0.331831	0.350476	0.360589	0.371142	0.376696	…	0.384793	0.385172	0.385559	0.385643	0.385725
4	0.772915	0.798770	0.818014	0.834255	0.854442	…	0.912094	0.918484	0.927652	0.928116	0.928336
5	0.657502	0.684862	0.732506	0.915536	0.947140	…	1.006381	1.014569	1.015436	1.016716	1.016750
9	0.765279	0.821772	0.869223	0.922635	0.944188	…	1.034155	1.042150	1.043844	1.043844	1.043844
10	0.722222	0.736671	0.742894	0.753818	0.757018	…	0.763757	0.764335	0.764335	0.764335	0.764335

7 rows × 13 columns

In [223…
```
plt.figure(figsize=(15, 6));
plt.title('Накопительный ROMI по разным источникам и периодам');
sns.heatmap(romi_table, annot=True, fmt='.2f', linewidths=1, linecolor='gray');
plt.xlabel('Время жизни когорты');
plt.ylabel('Источник');
```

Как показал анализ, на конец выборки окупились источники 1, 2, 5 и 9. Причем лидером является источник 1, он же окупился уже после 1 периода. Расходным источником с ROMI = 0.4 остался номер 3. Причем источник 4, несмотря на то, что не вышел на показатель 1, показывает устойчивый рост со временем. Источник 10 имеет ROMI = 0.7, но никак не изменялся по времени, что может быть связано с тем, что бюджета на этот источник практически не было.

Вывод раздела 2

В этом разделе были проведены расчеты различных метрик с построены графики для визуализации.

1. Подготовили отчет по продукту

- Выявлены отличия в пользователях с настольных систем и смартфонов. Пользователей с настольных систем практически в 3 раза больше пользователей со смартфонам, как в день, так и в неделю и месяц (600 против 221 в день).
- В среднем каждый пользователь заходил на сайт чуть более одного раза, по количеству сессий в день также лидируют визиты с настольных систем (656 против 233).
- Сессии по медиане длятся около 6 минут для настольных систем и 3 минуты для смартфонов.
- На сайт возвращает оцень малая часть посетителей в следующие периоды (до 7%). Пользователи настольных систем возвращаются на 2 процентных пункты чаще, чем пользователи смартфонов?

2. Рассчитали метрики продаж

- Проведен расчет времени первой покупки после визита пользователей по платформам и источникам. В 90% случаев пользователи делали заказ сразу, в остальных случаях заказ с мобильных устройств происходит быстрее, чем с настольных систем, можно выделить источники 6 и 7 как неэффективные.
- В отчете выделены когорты по времени первой покупки с июня 2017 года по июнь 2018 года.
- В среднем клиенты совершают порядка 4201 заказа в месяц, но показатель количества заказов на одного покупателя постоянно снижается. На конец выборки этот показатель около единицы, а значит количество заказов практически равно количеству новых покупателей.
- Средний чек для всех когорт в области 4-5, но в некоторые периоды для когорт сентября и декабря 2017 года средний чек вырастал вплоть до 53.2, что возможно, показывате сезонность бизнеса компании.
- Наибольшую валовую прибыль принесли когорты сентября 2017 года и июня 2017 года (13.4 и 11.9 соответственно), LTV для более поздних когорт падает с течением времени.

3. Провели анализ затрат на маркетинг

- Всего было потрачено 329131.62 на продвижение продукта, больше всего (43%) на источник тип 3. Расходы выросли в сентябре 2017 года и достигли пика в декабре 2017 года, далее затраты снижались.
- В среднем на привлечение одного клиента уходит около 10, пик стоимости привлечения пришелся на август 2018 года (10.8), далее затраты снижались с небольшим пиком в декабре 2017 года.
- По расчета показателя ROMI затраты на маркетинг окупились только 4 из 10 каналов привлечения, причем наибольшую скорость показал канал 1.

3. Общий вывод и рекомендации

По результатам анализа на текущий момент затраты на маркетинг не окупаются. В то же время, благодаря запуску типа источника покупателей 3 в августе 2017 года количество покупателей выросло практически в 3 раза, что сразу дало показатель окупаемости

свыше 1 в сентябре. В то же время, дальнейшие затраты на этот источник трафика не принес результата в связи с довольно низким средним чеком, что не дает окупиться затратам на привлечение клиентов. Было бы логично испробовать другие источники трафика и увеличить их финансирование за счет источника 3.

Так как больше всего пользователей приходят с настольных систем и только малая часть со смартфонов, стоит дополнительно рассмотреть маркетинговые акции и способы привлечения, нацеленные на пользователей смартфонов, так как, возможно, еще не исчерпан предел пользователем, которым был бы интересен сервис с мобильных устройств. В то же время, среднее время сессии на мобильных устройствах ниже и количество визитов также ниже, чем для настольных систем.

С учетом показателей метрики LTV валовой прибыли с клиента и низкой доли возвращающихся клиентов стоит рассмотреть дополнительные маркетинговый акции, направленные на удержание клиента (например, бонусная программа). Как показывает анализ затраты на привлечение пользовательских когорт могут окупаться спустя несколько месяцев, поэтому очень важно привлекать клиентов, которые уже попробовали продукт.

Как показал анализ, на конец выборки окупились источники 1, 2, 5 и 9. С точки зрения использования маркетингового бюджета стоит сохранить канал привлечения 1, но сократить расходы на каналы 3 и 4, так как их привлечение не окупается, а больше всего средств расходуется на канал 3. 4 канал в долгосрочной перспективе смог бы окупится, но он требует слишком большого бюджета, а ROMI растет слишком медленно. Каналы 6, 7, 8 практически не принесли новых заказов, но и бюджет на них был минимален. Стоит внимательнее отнестись к этим источникам, так как они могут как являться точкой потенциального роста, так и просто привлекать не ту аудиторию и развивать их не имеет смысла. Источник 10 показал стабильный результат, но за счет того, что бюджет на него не изменялся, возможно не смог раскрыть весь свой потенциал.